

16_comparacion_cualitativa_cuantitativa_LORA_vs_hiperparametros

May 22, 2026

1 16. Evaluación integral cuantitativa + cualitativa interna

Este notebook integra los resultados cuantitativos y cualitativos de los 6 sistemas finales evaluados sobre la muestra representativa de 36 textos.

Los sistemas comparados son:

1. few-shot_hariel_llama3_llama3_cfg_3_R1
2. few-shot_nancy_llama3_llama3_cfg_2_R2
3. zero-shot_hariel_llama3_hariel_llama3_cfg_1_R0
4. zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4
5. lora_llama3
6. lora_mistral

La evaluación cuantitativa considera las métricas automáticas usadas en el TT:

- SARI
- BLEU
- BERTScore F1
- ROUGE-1 F1
- ROUGE-2 F1
- ROUGE-L F1
- Fernández-Huerta
- INFLESHZ
- Compression ratio
- Sentence splits
- Levenshtein similarity
- Exact copy
- Additions proportion
- Deletions proportion

Además, se conserva `leader_score` como métrica líder, calculada a partir de SARI y BERTScore.

La evaluación cualitativa corresponde a la rúbrica interna aplicada manualmente a los 6 sistemas finales.

```
[1]: from pathlib import Path
import sys
import re
```

```

import unicodedata
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

pd.set_option("display.max_columns", 160)
pd.set_option("display.max_colwidth", 160)

PROJECT_ROOT = Path("/home/harielpadillasanchez/Documentos/TT/TT2")

DATA_DIR = PROJECT_ROOT / "data"
CUALITATIVA_DIR = DATA_DIR / "cualitativa"
QUAL_INTERNAL_PATH = CUALITATIVA_DIR / "Evaluacion_cualitativa_interna.xlsx"

OUT_DIR = PROJECT_ROOT / "outputs" /
    ↪ "evaluacion_integral_lora_vs_hiperparametros"
OUT_DIR.mkdir(parents=True, exist_ok=True)

print("PROJECT_ROOT:", PROJECT_ROOT, "| existe:", PROJECT_ROOT.exists())
print("DATA_DIR:", DATA_DIR, "| existe:", DATA_DIR.exists())
print("CUALITATIVA_DIR:", CUALITATIVA_DIR, "| existe:", CUALITATIVA_DIR.
    ↪exists())
print("QUAL_INTERNAL_PATH:", QUAL_INTERNAL_PATH, "| existe:",
    ↪QUAL_INTERNAL_PATH.exists())
print("OUT_DIR:", OUT_DIR)

if not QUAL_INTERNAL_PATH.exists():
    raise FileNotFoundError(f"No existe el archivo: {QUAL_INTERNAL_PATH}")

```

```

PROJECT_ROOT: /home/harielpadillasanchez/Documentos/TT/TT2 | existe: True
DATA_DIR: /home/harielpadillasanchez/Documentos/TT/TT2/data | existe: True
CUALITATIVA_DIR: /home/harielpadillasanchez/Documentos/TT/TT2/data/cualitativa |
existe: True
QUAL_INTERNAL_PATH: /home/harielpadillasanchez/Documentos/TT/TT2/data/cualitativ
a/Evaluacion_cualitativa_interna.xlsx | existe: True
OUT_DIR: /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integra
l_lora_vs_hiperparametros

```

```

[2]: COMPUTE_BERTSCORE = True
# Ponderación final.
# 50/50 permite que el resultado no dependa solo de métricas automáticas.
WEIGHT_QUANT = 0.50
WEIGHT_QUAL = 0.50

assert abs(WEIGHT_QUANT + WEIGHT_QUAL - 1.0) < 1e-9

# Target usado para evaluar compression ratio.

```

```

# Un valor menor a 1 indica que el texto se redujo.
# 0.85 busca favorecer reducción moderada, sin castigar demasiado textos_
↳ cercanos al original.
COMPRESSION_TARGET = 0.85

print("COMPUTE_BERTSCORE:", COMPUTE_BERTSCORE)
print("WEIGHT_QUANT:", WEIGHT_QUANT)
print("WEIGHT_QUAL:", WEIGHT_QUAL)
print("COMPRESSION_TARGET:", COMPRESSION_TARGET)

```

```

COMPUTE_BERTSCORE: True
WEIGHT_QUANT: 0.5
WEIGHT_QUAL: 0.5
COMPRESSION_TARGET: 0.85

```

```

[3]: # IMPORTANTE:
# Este orden debe coincidir con el orden en que están acomodados los bloques
# dentro del Excel de evaluación cualitativa interna.
#
# Prompting:
# filas 1-36 -> sistema 1
# filas 37-72 -> sistema 2
# filas 73-108 -> sistema 3
# filas 109-144 -> sistema 4
#
# LoRA:
# filas 1-36 -> lora_llama3
# filas 37-72 -> lora_mistral

PROMPTING_SYSTEM_ORDER = [
    "few-shot_hariel_llama3_llama3_cfg_3_R1",
    "few-shot_nancy_llama3_llama3_cfg_2_R2",
    "zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4",
    "zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4",
]

LORA_SYSTEM_ORDER = [
    "lora_mistral",
    "lora_llama3",
]

ALL_SYSTEM_ORDER = PROMPTING_SYSTEM_ORDER + LORA_SYSTEM_ORDER

print("Sistemas prompting:")
for i, s in enumerate(PROMPTING_SYSTEM_ORDER, start=1):
    print(i, s)

```

```

print("\nSistemas LoRA:")
for i, s in enumerate(LORA_SYSTEM_ORDER, start=1):
    print(i, s)

print("\nTotal sistemas:", len(ALL_SYSTEM_ORDER))

```

Sistemas prompting:

```

1 few-shot_hariel_llama3_llama3_cfg_3_R1
2 few-shot_nancy_llama3_llama3_cfg_2_R2
3 zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4
4 zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4

```

Sistemas LoRA:

```

1 lora_mistral
2 lora_llama3

```

Total sistemas: 6

```

[4]: QUANT_METRICS = [
    "sari",
    "bleu",
    "bertscore_f1",
    "rouge1_f",
    "rouge2_f",
    "rougeL_f",
    "fernandez_huerta_pred",
    "fernandez_huerta_src",
    "fernandez_huerta_delta",
    "inflesz_pred",
    "inflesz_src",
    "inflesz_delta",
    "compression_ratio_eval",
    "sentence_splits",
    "levenshtein_similarity",
    "exact_copy",
    "additions_proportion",
    "deletions_proportion",
]

LEADER_METRICS = [
    "sari",
    "bertscore_f1",
]

print("Métricas cuantitativas:")
for m in QUANT_METRICS:
    print("-", m)

```

Métricas cuantitativas:

- sari
- bleu
- bertscore_f1
- rouge1_f
- rouge2_f
- rougeL_f
- fernandez_huerta_pred
- fernandez_huerta_src
- fernandez_huerta_delta
- inflesz_pred
- inflesz_src
- inflesz_delta
- compression_ratio_eval
- sentence_splits
- levenshtein_similarity
- exact_copy
- additions_proportion
- deletions_proportion

```
[5]: TEXT_ID_COL = "Texto"

CRITERIA_COLS = [
    "Semántica (5|3|1)",
    "Claridad (5|3|1)",
    "Fluidez y corrección (5|3|1)",
    "Léxico y sintaxis (5|3|1)",
    "Adecuación al público / tono (5|3|1)",
    "Estructura y presentación (5|3|1)",
    "Manejo de números y datos (5|3|1)",
]

CRITERIA_RENAME = {
    "Semántica (5|3|1)": "score_fidelidad",
    "Claridad (5|3|1)": "score_comprension",
    "Fluidez y corrección (5|3|1)": "score_fluidez",
    "Léxico y sintaxis (5|3|1)": "score_lexico",
    "Adecuación al público / tono (5|3|1)": "score_tono",
    "Estructura y presentación (5|3|1)": "score_estructura",
    "Manejo de números y datos (5|3|1)": "score_numeros",
}

QUAL_SCORE_COLS = list(CRITERIA_RENAME.values())

# Pesos usados en la rúbrica.
# Estos pesos suman 100.
QUAL_WEIGHTS = {
```

```

    "score_fidelidad": 25,
    "score_comprension": 25,
    "score_fluidez": 15,
    "score_lexico": 10,
    "score_tono": 10,
    "score_estructura": 10,
    "score_numeros": 5,
}

assert sum(QUAL_WEIGHTS.values()) == 100

print("Criterios cualitativos:")
for col, weight in QUAL_WEIGHTS.items():
    print(f"{col}: {weight}%")

```

```

Criterios cualitativos:
score_fidelidad: 25%
score_comprension: 25%
score_fluidez: 15%
score_lexico: 10%
score_tono: 10%
score_estructura: 10%
score_numeros: 5%

```

```

[6]: xls = pd.ExcelFile(QUAL_INTERNAL_PATH)

print("Hojas disponibles:")
for i, sheet in enumerate(xls.sheet_names, start=1):
    print(f"{i}. {sheet}")

```

```

Hojas disponibles:
1. Rúbrica
2. Textos simplificados
3. Evaluación cualitativa
4. Textos simplificados Fine-tunin
5. Evaluación cualitativa fine tun

```

```

[7]: def normalize_text_for_match(text):
    """
    Normaliza texto para comparar coincidencias aproximadas:
    - Convierte NaN a cadena vacía.
    - Normaliza Unicode.
    - Elimina saltos de línea y espacios repetidos.
    - Pasa a minúsculas.
    """
    if pd.isna(text):
        return ""

```

```

text = str(text)
text = unicodedata.normalize("NFKC", text)
text = text.replace("\n", " ").replace("\r", " ").replace("\t", " ")
text = re.sub(r"\s+", " ", text).strip().lower()

return text

def preview_df(df, name="df", n=3):
    print(f"{name} shape:", df.shape)
    print(f"{name} columnas:", df.columns.tolist())
    display(df.head(n))

def clean_string_columns(df):
    df = df.copy()
    for col in df.columns:
        if df[col].dtype == "object":
            df[col] = df[col].apply(lambda x: re.sub(r"\s+", " ", str(x)).
↳strip() if not pd.isna(x) else x)
    return df

```

```

[8]: def read_internal_texts(path: Path, sheet_name: str) -> pd.DataFrame:
    """
    Lee una hoja de textos simplificados del Excel interno.

    Estructura esperada:
    - id
    - Texto original
    - Texto de referencia
    - Texto simplificado por el LLM
    """
    df = pd.read_excel(path, sheet_name=sheet_name)
    df = df.dropna(axis=1, how="all").copy()

    required_cols = [
        "id",
        "Texto original",
        "Texto de referencia",
        "Texto simplificado por el LLM",
    ]

    missing = [c for c in required_cols if c not in df.columns]
    if missing:
        raise ValueError(
            f"Faltan columnas en hoja '{sheet_name}': {missing}\n"
            f"Columnas encontradas: {df.columns.tolist()}"

```

```

    )

    df = df[required_cols].copy()

    # Conservar filas con id numérico.
    df = df[pd.to_numeric(df["id"], errors="coerce").notna()].copy()
    df["id"] = pd.to_numeric(df["id"], errors="coerce").astype(int)

    df = df.rename(
        columns={
            "id": "texto_eval_id",
            "Texto original": "source_text",
            "Texto de referencia": "reference_text",
            "Texto simplificado por el LLM": "generated_text",
        }
    )

    df = clean_string_columns(df)

    return df.reset_index(drop=True)

```

```

[9]: def read_internal_scores(path: Path, sheet_name: str) -> pd.DataFrame:
    """
    Lee una hoja de evaluación cualitativa del Excel interno.

    Esta versión normaliza los nombres de columnas para evitar errores
    por dobles espacios, por ejemplo:
    'Semántica (5/3/1)' -> 'Semántica (5/3/1)'
    """
    df = pd.read_excel(path, sheet_name=sheet_name)
    df = df.dropna(axis=1, how="all").copy()

    # Normalizar nombres de columnas.
    df.columns = [normalize_col_name(c) for c in df.columns]

    required_cols = [TEXT_ID_COL] + CRITERIA_COLS

    missing = [c for c in required_cols if c not in df.columns]
    if missing:
        raise ValueError(
            f"Faltan columnas en hoja '{sheet_name}': {missing}\n"
            f"Columnas encontradas: {df.columns.tolist()}"
        )

    keep_cols = required_cols.copy()

    if "Puntaje Final" in df.columns:

```



```

        keep_cols.append("Puntaje Final")

df = df[keep_cols].copy()

# Quitar fila de pesos y filas vacías.
df = df[pd.to_numeric(df[TEXT_ID_COL], errors="coerce").notna()].copy()
df[TEXT_ID_COL] = pd.to_numeric(df[TEXT_ID_COL], errors="coerce").
↳astype(int)

df = df.rename(columns={TEXT_ID_COL: "texto_eval_id"})
df = df.rename(columns=CRITERIA_RENAME)

for col in QUAL_SCORE_COLS:
    df[col] = pd.to_numeric(df[col], errors="coerce")

if "Puntaje Final" in df.columns:
    df["puntaje_final_excel"] = pd.to_numeric(df["Puntaje Final"],
↳errors="coerce")
    df = df.drop(columns=["Puntaje Final"])

return df.reset_index(drop=True)

```

[10]: TEXT_ID_COL = "Texto"

```

# Versión normalizada de los nombres.
# Así no importa si en Excel hay uno o dos espacios.
CRITERIA_COLS = [
    "Semántica (5|3|1)",
    "Claridad (5|3|1)",
    "Fluidez y corrección (5|3|1)",
    "Léxico y sintaxis (5|3|1)",
    "Adecuación al público / tono (5|3|1)",
    "Estructura y presentación (5|3|1)",
    "Manejo de números y datos (5|3|1)",
]

CRITERIA_RENAME = {
    "Semántica (5|3|1)": "score_fidelidad",
    "Claridad (5|3|1)": "score_comprension",
    "Fluidez y corrección (5|3|1)": "score_fluidez",
    "Léxico y sintaxis (5|3|1)": "score_lexico",
    "Adecuación al público / tono (5|3|1)": "score_tono",
    "Estructura y presentación (5|3|1)": "score_estructura",
    "Manejo de números y datos (5|3|1)": "score_numeros",
}

QUAL_SCORE_COLS = list(CRITERIA_RENAME.values())

```

```

QUAL_WEIGHTS = {
    "score_fidelidad": 25,
    "score_comprension": 25,
    "score_fluidez": 15,
    "score_lexico": 10,
    "score_tono": 10,
    "score_estructura": 10,
    "score_numeros": 5,
}

assert sum(QUAL_WEIGHTS.values()) == 100

def normalize_col_name(col):
    """
    Normaliza nombres de columnas:
    - Convierte a string.
    - Reemplaza espacios múltiples por uno.
    - Quita espacios al inicio y final.
    """
    col = str(col)
    col = re.sub(r"\s+", " ", col)
    return col.strip()

print("Criterios cualitativos:")
for col, weight in QUAL_WEIGHTS.items():
    print(f"{col}: {weight}%")

```

```

Criterios cualitativos:
score_fidelidad: 25%
score_comprension: 25%
score_fluidez: 15%
score_lexico: 10%
score_tono: 10%
score_estructura: 10%
score_numeros: 5%

```

```

[11]: SHEET_TEXTS_PROMPT = "Textos simplificados"
      SHEET_SCORES_PROMPT = "Evaluación cualitativa"

      SHEET_TEXTS_LORA = "Textos simplificados Fine-tunin"
      SHEET_SCORES_LORA = "Evaluación cualitativa fine tun"

      texts_prompt = read_internal_texts(
          QUAL_INTERNAL_PATH,
          SHEET_TEXTS_PROMPT
      )

```

```

scores_prompt = read_internal_scores(
    QUAL_INTERNAL_PATH,
    SHEET_SCORES_PROMPT
)

texts_lora = read_internal_texts(
    QUAL_INTERNAL_PATH,
    SHEET_TEXTS_LORA
)

scores_lora = read_internal_scores(
    QUAL_INTERNAL_PATH,
    SHEET_SCORES_LORA
)

preview_df(texts_prompt, "texts_prompt")
preview_df(scores_prompt, "scores_prompt")
preview_df(texts_lora, "texts_lora")
preview_df(scores_lora, "scores_lora")

```

texts_prompt shape: (144, 4)

texts_prompt columns: ['texto_eval_id', 'source_text', 'reference_text', 'generated_text']

```

    texto_eval_id \
0                1
1                2
2                3

```

```

    source_text \
0
    tiene incentivos ni motivación, dos elementos esenciales en ambientes de
    competencia.
1 En los procesos de importaciones y exportaciones intervienen, además de
    clientes y proveedores, instituciones del Estado y los bancos, tal como se
    indica en...
2 El robo de identidad ocurre cuando su información personal, tal como su
    nombre, número de cuenta, o número de cédula de identidad se usan sin su
    conocimiento...

```

```

    reference_text \

```

0 □
 ↳No tiene sentido ni motivación. Estos elementos son esenciales para la□
 ↳competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones.□
 ↳También lo hacen las instituciones estatales y los banco como se indica a□
 ↳continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre,□
 ↳número de cuenta, o número de cédula de identidad se usan sin su conocimiento□
 ↳par...

□

↳ □
 ↳generated_text

0 Sin□
 ↳motivación y sin incentivos no se puede trabajar bien en un ambiente□
 ↳competitivo.

1 En la importación y exportación, también□
 ↳participan instituciones gubernamentales y bancos, como se muestra a□
 ↳continuación.

2 El robo de identidad es cuando alguien utiliza tu información personal, como□
 ↳tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer□
 ↳...

scores_prompt shape: (144, 9)

scores_prompt columns: ['texto_eval_id', 'score_fidelidad',
 'score_comprension', 'score_fluidez', 'score_lexico', 'score_tono',
 'score_estructura', 'score_numeros', 'puntaje_final_excel']

	texto_eval_id	score_fidelidad	score_comprension	score_fluidez	\
0	1	5.0	5.0	5.0	
1	2	5.0	5.0	5.0	
2	3	5.0	5.0	5.0	

	score_lexico	score_tono	score_estructura	score_numeros	\
0	5.0	5.0	5.0	5.0	
1	5.0	5.0	5.0	5.0	
2	5.0	5.0	5.0	5.0	

	puntaje_final_excel
0	5.0
1	5.0
2	5.0

texts_lora shape: (72, 4)

texts_lora columns: ['texto_eval_id', 'source_text', 'reference_text',
 'generated_text']

	texto_eval_id	\
0	1	

```

1           2
2           3

```

```

↳
↳source_text \
0
↳tiene incentivos ni motivación, dos elementos esenciales en ambientes de
↳competencia.
1 En los procesos de importaciones y exportaciones intervienen, además de
↳clientes y proveedores, instituciones del Estado y los bancos, tal como se
↳indica en...
2 El robo de identidad ocurre cuando su información personal, tal como su
↳nombre, número de cuenta, o número de cédula de identidad se usan sin su
↳conocimient...

```

```

↳
↳reference_text \
0
↳No tiene sentido ni motivación. Estos elementos son esenciales para la
↳competencia.
1 Clientes y proveedores intervienen en las importancias y exportaciones.
↳También lo hacen las instituciones estatales y los banco como se indica a
↳continuación:
2 El robo de identidad ocurre cuando su información personal como su nombre,
↳número de cuenta, o número de cédula de identidad se usan sin su conocimiento
↳par...

```

```

↳
↳generated_text
0
↳No tiene incentivos ni motivación, dos
↳elementos esenciales en ambientes de competencia.
1 En los procesos de importaciones y exportaciones intervienen clientes y
↳proveedores, instituciones del Estado y los bancos.
2 El robo de identidad ocurre cuando su información personal se usa sin
↳su conocimiento para cometer un fraude o robo.

```

```

scores_lora shape: (73, 9)
scores_lora columns: ['texto_eval_id', 'score_fidelidad', 'score_comprension',
'score_fluidez', 'score_lexico', 'score_tono', 'score_estructura',
'score_numeros', 'puntaje_final_excel']

```

	texto_eval_id	score_fidelidad	score_comprension	score_fluidez	\
0	1	5.0	5.0	5.0	
1	2	5.0	5.0	5.0	
2	3	3.0	5.0	5.0	

	score_lexico	score_tono	score_estructura	score_numeros	\
0	3.0	5.0	5.0	5.0	
1	5.0	5.0	5.0	5.0	
2	5.0	5.0	5.0	5.0	

	puntaje_final_excel
0	4.8
1	5.0
2	4.5

```
[12]: qual_prompt = texts_prompt.merge(
        scores_prompt,
        on="texto_eval_id",
        how="inner"
    )

    qual_lora = texts_lora.merge(
        scores_lora,
        on="texto_eval_id",
        how="inner"
    )

    print("qual_prompt shape:", qual_prompt.shape)
    print("qual_lora shape:", qual_lora.shape)

    display(qual_prompt.head())
    display(qual_lora.head())

    if len(qual_prompt) != len(texts_prompt):
        print("Ojo: no coincidieron todas las filas de prompting.")

    if len(qual_lora) != len(texts_lora):
        print("Ojo: no coincidieron todas las filas de LoRA.")
```

```
qual_prompt shape: (144, 12)
qual_lora shape: (72, 12)
```

	texto_eval_id	\
0	1	
1	2	
2	3	
3	4	
4	5	

```
↳
↳source_text \
```

0 No
 ↳tiene incentivos ni motivación, dos elementos esenciales en ambientes de
 ↳competencia.

1 En los procesos de importaciones y exportaciones intervienen, además de
 ↳clientes y proveedores, instituciones del Estado y los bancos, tal como se
 ↳indica en...

2 El robo de identidad ocurre cuando su información personal, tal como su
 ↳nombre, número de cuenta, o número de cédula de identidad se usan sin su
 ↳conocimient...

3 Los sueños de los niños
 ↳tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por
 ↳Superman.

4 Expresiones como soborno y cohecho se refieren a
 ↳ilícitos vinculados a la compra de la voluntad de un individuo para provecho
 ↳personal.

↳

↳reference_text \

0 Sin
 ↳No tiene sentido ni motivación. Estos elementos son esenciales para la
 ↳competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones.
 ↳También lo hacen las instituciones estatales y los banco como se indica a
 ↳continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre,
 ↳número de cuenta, o número de cédula de identidad se usan sin su conocimiento
 ↳par...

3 Los
 ↳sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y
 ↳Superman.

4 Expresiones como soborno y cohecho se
 ↳refieren a delitos vinculados a comprar la voluntad de alguien para provecho
 ↳personal.

↳

↳generated_text \

0 Sin
 ↳motivación y sin incentivos no se puede trabajar bien en un ambiente
 ↳competitivo.

1 En la importación y exportación, también
 ↳participan instituciones gubernamentales y bancos, como se muestra a
 ↳continuación.

2 El robo de identidad es cuando alguien utiliza tu información personal, como
 ↳tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer
 ↳...

3 Los niños soñan con cosas como ser Tarzán, el Agente 007 o Superman.

4 Expresiones como "soborno" y "cohecho" se refieren a actos ilegales que involucran comprar el apoyo o consentimiento de alguien para beneficio propio.

	score_fidelidad	score_compension	score_fluidez	score_lexico	\
0	5.0	5.0	5.0	5.0	
1	5.0	5.0	5.0	5.0	
2	5.0	5.0	5.0	5.0	
3	5.0	3.0	5.0	1.0	
4	5.0	5.0	5.0	5.0	

	score_tono	score_estructura	score_numeros	puntaje_final_excel
0	5.0	5.0	5.0	5.0
1	5.0	5.0	5.0	5.0
2	5.0	5.0	5.0	5.0
3	5.0	5.0	5.0	4.1
4	5.0	5.0	5.0	5.0

	texto_eval_id	\
0	1	
1	2	
2	3	
3	4	
4	5	

source_text \

0 No tiene incentivos ni motivación, dos elementos esenciales en ambientes de competencia.

1 En los procesos de importaciones y exportaciones intervienen, además de clientes y proveedores, instituciones del Estado y los bancos, tal como se indica en...

2 El robo de identidad ocurre cuando su información personal, tal como su nombre, número de cuenta, o número de cédula de identidad se usan sin su conocimiento...

3 Los sueños de los niños tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por Superman.

4 Expresiones como soborno y cohecho se refieren a ilícitos vinculados a la compra de la voluntad de un individuo para provecho personal.

↪ reference_text \

0 No tiene sentido ni motivación. Estos elementos son esenciales para la competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones. También lo hacen las instituciones estatales y los banco como se indica a continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre, número de cuenta, o número de cédula de identidad se usan sin su conocimiento par...

3 Los sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y Superman.

4 Expresiones como soborno y cohecho se refieren a delitos vinculados a comprar la voluntad de alguien para provecho personal.

↪ generated_text \

0 No tiene incentivos ni motivación, dos elementos esenciales en ambientes de competencia.

1 En los procesos de importaciones y exportaciones intervienen clientes y proveedores, instituciones del Estado y los bancos.

2 El robo de identidad ocurre cuando su información personal se usa sin su conocimiento para cometer un fraude o robo.

3 Los sueños de los niños tienen una gran variedad. Algunos son Tarzán, el Agente 007 o Superman.

4 Expresiones como soborno y cohecho son ilícitos vinculados a la compra de la voluntad de un individuo para provecho personal.

	score_fidelidad	score_compension	score_fluidez	score_lexico	\
0	5.0	5.0	5.0	3.0	
1	5.0	5.0	5.0	5.0	
2	3.0	5.0	5.0	5.0	
3	5.0	5.0	5.0	5.0	
4	5.0	5.0	5.0	3.0	

	score_tono	score_estructura	score_numeros	puntaje_final_excel
0	5.0	5.0	5.0	4.8
1	5.0	5.0	5.0	5.0
2	5.0	5.0	5.0	4.5
3	5.0	5.0	5.0	5.0
4	3.0	5.0	5.0	4.6

```
[13]: def assign_system_by_blocks(df: pd.DataFrame, system_order: list[str],
↳ block_size: int = 36) -> pd.DataFrame:
    """
    Asigna nombre de sistema suponiendo que la hoja está organizada en bloques.

    Ejemplo con block_size=36:
    filas 1-36 -> sistema 1
    filas 37-72 -> sistema 2
    etc.
    """
    out = df.copy()

    out["block_index"] = ((out["texto_eval_id"] - 1) // block_size).astype(int)

    max_block = out["block_index"].max()

    if max_block >= len(system_order):
        raise ValueError(
            f"Hay más bloques de los esperados. "
            f"Bloque máximo={max_block}, número de sistemas={len(system_order)}"
        )

    out["system_name"] = out["block_index"].apply(lambda i: system_order[i])
    out["position_in_system"] = ((out["texto_eval_id"] - 1) % block_size) + 1

    return out

qual_prompt = assign_system_by_blocks(
    qual_prompt,
    system_order=PROMPTING_SYSTEM_ORDER,
    block_size=36
)

qual_lora = assign_system_by_blocks(
    qual_lora,
    system_order=LORA_SYSTEM_ORDER,
    block_size=36
)

qual_prompt["system_family"] = "prompting"
qual_lora["system_family"] = "lora"

qual_detail = pd.concat([qual_prompt, qual_lora], ignore_index=True)

print("qual_detail shape:", qual_detail.shape)
```

```

display(
  qual_detail[
    [
      "texto_eval_id",
      "position_in_system",
      "system_name",
      "system_family",
      "source_text",
      "generated_text",
    ] + QUAL_SCORE_COLS
  ].head(12)
)

display(
  qual_detail[
    [
      "texto_eval_id",
      "position_in_system",
      "system_name",
      "system_family",
      "source_text",
      "generated_text",
    ] + QUAL_SCORE_COLS
  ].tail(12)
)

```

qual_detail shape: (216, 16)

	texto_eval_id	position_in_system	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1
5	6	6	few-shot_hariel_llama3_llama3_cfg_3_R1
6	7	7	few-shot_hariel_llama3_llama3_cfg_3_R1
7	8	8	few-shot_hariel_llama3_llama3_cfg_3_R1
8	9	9	few-shot_hariel_llama3_llama3_cfg_3_R1
9	10	10	few-shot_hariel_llama3_llama3_cfg_3_R1
10	11	11	few-shot_hariel_llama3_llama3_cfg_3_R1
11	12	12	few-shot_hariel_llama3_llama3_cfg_3_R1

	system_family \
0	prompting
1	prompting
2	prompting
3	prompting
4	prompting

```
5      prompting
6      prompting
7      prompting
8      prompting
9      prompting
10     prompting
11     prompting
```

↪ generated_text \

0 ↪ Sin motivación y sin incentivos no se puede trabajar bien en un ambiente ↪
 ↪ competitivo.

1 En la importación y exportación, también ↪
 ↪ participan instituciones gubernamentales y bancos, como se muestra a ↪
 ↪ continuación.

2 El robo de identidad es cuando alguien utiliza tu información personal, como ↪
 ↪ tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer ↪
 ↪ ...

3 Los niños soñan con cosas como ser Tarzán, el Agente 007 o ↪
 ↪ Superman.

4 Expresiones como "soborno" y "cohecho" se refieren a actos ilegales ↪
 ↪ que involucran comprar el apoyo o consentimiento de alguien para beneficio ↪
 ↪ propio.

5 La ↪
 ↪ Dirección de Presupuesto es responsable de crear y supervisar los presupuestos ↪
 ↪ del país.

6 El interés compuesto es la suma del capital y el interés acumulado, que ↪
 ↪ crece según el tiempo convenido. La tasa de interés es el porcentaje aplicado ↪
 ↪ a un p...

7 La producción ↪
 ↪ en un país se hace utilizando factores como capital, trabajo y recursos ↪
 ↪ naturales.

8 Aunque algunos lo critiquen, el intermediario es necesario en la ↪
 ↪ economía.

9 El impuesto sobre los ↪
 ↪ intereses es una forma efectiva de medir el valor de las rentas y la riqueza ↪
 ↪ del país.

10 Separar las metas en tres períodos de tiempo es útil para planificar. Esto ↪
 ↪ ya se mencionó anteriormente, pero es importante recordarlo para gestionar ↪
 ↪ mejor ...

11 La seguridad financiera es importante porque te permite pagar tus ↪
 ↪ necesidades actuales y futuras, así como también cumple con tus compromisos ↪
 ↪ diarios.

	score_fidelidad	score_comprension	score_fluidez	score_lexico \
0	5.0	5.0	5.0	5.0
1	5.0	5.0	5.0	5.0
2	5.0	5.0	5.0	5.0
3	5.0	3.0	5.0	1.0
4	5.0	5.0	5.0	5.0

5	5.0	5.0	5.0	5.0
6	5.0	5.0	5.0	5.0
7	5.0	3.0	5.0	5.0
8	5.0	5.0	5.0	5.0
9	5.0	5.0	5.0	5.0
10	5.0	5.0	5.0	5.0
11	5.0	5.0	5.0	5.0

	score_tono	score_estructura	score_numeros
0	5.0	5.0	5.0
1	5.0	5.0	5.0
2	5.0	5.0	5.0
3	5.0	5.0	5.0
4	5.0	5.0	5.0
5	5.0	5.0	5.0
6	5.0	5.0	5.0
7	5.0	3.0	5.0
8	5.0	5.0	5.0
9	5.0	5.0	5.0
10	5.0	5.0	5.0
11	5.0	5.0	5.0

	texto_eval_id	position_in_system	system_name	system_family	\
204	61	25	lora_llama3	lora	
205	62	26	lora_llama3	lora	
206	63	27	lora_llama3	lora	
207	64	28	lora_llama3	lora	
208	65	29	lora_llama3	lora	
209	66	30	lora_llama3	lora	
210	67	31	lora_llama3	lora	
211	68	32	lora_llama3	lora	
212	69	33	lora_llama3	lora	
213	70	34	lora_llama3	lora	
214	71	35	lora_llama3	lora	
215	72	36	lora_llama3	lora	

↪

↪source_text \

204

↪ ¿Qué función cumplen las empresas en la

↪sociedad?

205 Estos principios están diseñados para promover que las firmas de servicios

↪financieros y las organizaciones de consumidores hagan más para educar a los

↪ciud...

206 Hable con

↪ellos, déles la cara, y hágales saber que está haciendo todo lo que puede para

↪pagarles.

207 Pero ¿en qué se ┐
↳ compete?
208 Por otra parte, algunas personas ┐
↳ sostienen que un impuesto de 10 por ciento impondría el mismo sacrificio a ┐
↳ ambas familias.
209 Al principio, como ya vimos en el trueque, adoptó la forma de mercancía, ┐
↳ pero con el tiempo se transformó en dinero-papel, cuentas corrientes y otras ┐
↳ formas.
210 ¿Son estos sólo sueños, o son metas ┐
↳ reales?
211 En los pueblos donde el ┐
↳ principio de la elección se extiende a todo, no hay propiamente hablando ┐
↳ carrera pública.
212 Sin entusiasmo, dijo alguien famoso, nunca se ha podido realizar nada ┐
↳ grande.
213 Por tanto, este método calcula interés sobre ┐
↳ interés.
214 El resultado es aproximado a \$300,000 en seis ┐
↳ años.
215 Documente todos sus ┐
↳ gastos e ingresos o compárelos con lo que usted planificó que iba a gastar en ┐
↳ el mes.
↳ generated_text ┐
↳ \

204 ¿Qué función cumplen las empresas en la sociedad? ┐
↳
205 Estos principios promueven que las firmas de servicios ┐
↳ financieros y las organizaciones de consumidores educen a los ciudadanos en ┐
↳ esta área.
206 Comuníquese con ellos, ┐
↳ déles la cara y hágales saber que está haciendo todo lo posible para pagarles.
207 ¿En qué se compete? ┐
↳
208 Algunas personas sostienen que ┐
↳ un impuesto de diez por ciento impondría el mismo sacrificio a ambas familias.
209 Al principio, como vimos en el trueque, adoptó la forma de mercancía. Pero ┐
↳ con el tiempo se transformó en dinero-papel, cuentas corrientes y otras formas.
210 ¿Son estos sueños o metas reales? ┐
↳

```

211             En los pueblos donde el principio
↳ de la elección se extiende a todo, no hay propiamente hablando carrera pública.
212
↳ Sin entusiasmo, nunca se ha podido realizar nada grande.
213
↳ Por eso, este método calcula interés sobre interés.
214
↳ El resultado es aproximadamente trescientos mil dólares en seis años.
215
↳ Documente todos sus gastos e ingresos.

```

	score_fidelidad	score_comprension	score_fluidez	score_lexico	\
204	5.0	5.0	5.0	5.0	
205	5.0	5.0	5.0	5.0	
206	5.0	5.0	5.0	5.0	
207	3.0	5.0	5.0	5.0	
208	5.0	5.0	5.0	5.0	
209	5.0	5.0	5.0	5.0	
210	5.0	5.0	5.0	5.0	
211	5.0	5.0	5.0	5.0	
212	5.0	5.0	5.0	5.0	
213	5.0	5.0	5.0	5.0	
214	5.0	5.0	5.0	5.0	
215	1.0	3.0	5.0	5.0	

	score_tono	score_estructura	score_numeros
204	5.0	5.0	5.0
205	5.0	5.0	5.0
206	5.0	5.0	5.0
207	5.0	5.0	5.0
208	5.0	5.0	5.0
209	5.0	5.0	5.0
210	5.0	5.0	5.0
211	5.0	5.0	5.0
212	5.0	5.0	5.0
213	5.0	5.0	5.0
214	5.0	5.0	5.0
215	5.0	5.0	5.0

```

[14]: expected_rows = 36 * 6

print("Filas esperadas:", expected_rows)
print("Filas encontradas:", len(qual_detail))

if len(qual_detail) != expected_rows:
    print("Ojo: la cantidad de filas no es 216. Revisa el Excel o el block_size.
↳")

```



```

else:
    print("OK: hay 216 filas, equivalentes a 36 textos x 6 sistemas.")

print("\nRegistros por sistema:")
display(
    qual_detail
    .groupby(["system_family", "system_name"], as_index=False)
    .agg(n=("texto_eval_id", "count"))
)

```

Filas esperadas: 216

Filas encontradas: 216

OK: hay 216 filas, equivalentes a 36 textos x 6 sistemas.

Registros por sistema:

	system_family	system_name	n
0	lora	lora_llama3	36
1	lora	lora_mistral	36
2	prompting	few-shot_hariel_llama3_llama3_cfg_3_R1	36
3	prompting	few-shot_nancy_llama3_llama3_cfg_2_R2	36
4	prompting	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	36
5	prompting	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	36

```
[15]: qual_detail["sample36_id"] = qual_detail["position_in_system"].astype(int)
```

```

display(
    qual_detail[
        [
            "sample36_id",
            "texto_eval_id",
            "system_name",
            "system_family",
            "source_text",
            "reference_text",
            "generated_text",
        ]
    ].head(10)
)

```

	sample36_id	texto_eval_id	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1
5	6	6	few-shot_hariel_llama3_llama3_cfg_3_R1
6	7	7	few-shot_hariel_llama3_llama3_cfg_3_R1
7	8	8	few-shot_hariel_llama3_llama3_cfg_3_R1

```

8          9          9  few-shot_hariel_llama3_llama3_cfg_3_R1
9          10         10  few-shot_hariel_llama3_llama3_cfg_3_R1

```

```

    system_family \
0    prompting
1    prompting
2    prompting
3    prompting
4    prompting
5    prompting
6    prompting
7    prompting
8    prompting
9    prompting

```

```

↪
↪source_text \
0                                     No
↪tiene incentivos ni motivación, dos elementos esenciales en ambientes de
↪competencia.
1  En los procesos de importaciones y exportaciones intervienen, además de
↪clientes y proveedores, instituciones del Estado y los bancos, tal como se
↪indica en...
2  El robo de identidad ocurre cuando su información personal, tal como su
↪nombre, número de cuenta, o número de cédula de identidad se usan sin su
↪conocimient...
3                                     Los sueños de los niños
↪tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por
↪Superman.
4                                     Expresiones como soborno y cohecho se refieren a
↪ilícitos vinculados a la compra de la voluntad de un individuo para provecho
↪personal.
5                                     DIRECCIÓN
↪DE PRESUPUESTO (DIPRES): "formula y lleva el control presupuestario de la
↪nación."
6  Interés compuesto: Es la suma del capital y el interés acumulado, que se va
↪multiplicando según los plazos convenidos. La tasa de interés es el porcentaje
↪q...
7                                     La producción en un país se realiza mediante lo que se conoce
↪como factores de producción y de los cuales nos ocuparemos en detalle más
↪adelante.
8                                     A pesar de
↪que algunos critican al intermediario, se necesita a este individuo en la
↪economía.

```

9 El impuesto a los réditos es también,
 ↳un buen instrumento para conocer el monto de las rentas y de la riqueza,
 ↳nacional.

↳

↳reference_text \

0 No tiene sentido ni motivación. Estos elementos son esenciales para la,
 ↳competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones.
 ↳También lo hacen las instituciones estatales y los banco como se indica a,
 ↳continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre,
 ↳número de cuenta, o número de cédula de identidad se usan sin su conocimiento,
 ↳par...

3 Los
 ↳sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y
 ↳Superman.

4 Expresiones como soborno y cohecho se,
 ↳refieren a delitos vinculados a comprar la voluntad de alguien para provecho,
 ↳personal.

5 DIRECCIÓN DE PRESUPUESTO: formula y lleva el control presupuestario de la,
 ↳nación.

6 El interés compuesto es la suma del capital y el interés acumulado.
 ↳La tasa de interés es el porcentaje aplicado a un préstamo o inversión,
 ↳realizada.

7 A través de los factores de producción se realiza,
 ↳la producción en un país. Más adelante nos ocuparemos en detalle de estos,
 ↳factores.

8 Aunque
 ↳algunas personas critican al intermediario, este individuo es necesario en la,
 ↳economía.

9 El impuesto a las utilidades,
 ↳también es un buen método para conocer el monto de las rentas y de la riqueza,
 ↳nacional.

↳

↳generated_text

0 Sin
 ↳motivación y sin incentivos no se puede trabajar bien en un ambiente,
 ↳competitivo.

1 En la importación y exportación, también,
 ↳participan instituciones gubernamentales y bancos, como se muestra a,
 ↳continuación.

- 2 El robo de identidad es cuando alguien utiliza tu información personal, como
 ↳ tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer
 ↳ ...
- 3 Los niños soñan con cosas como ser Tarzán, el Agente 007 o
 ↳ Superman.
- 4 Expresiones como "soborno" y "cohecho" se refieren a actos ilegales
 ↳ que involucran comprar el apoyo o consentimiento de alguien para beneficio
 ↳ propio.
- 5 La
 ↳ Dirección de Presupuesto es responsable de crear y supervisar los presupuestos
 ↳ del país.
- 6 El interés compuesto es la suma del capital y el interés acumulado, que crece
 ↳ según el tiempo convenido. La tasa de interés es el porcentaje aplicado a un p...
- 7 La producción
 ↳ en un país se hace utilizando factores como capital, trabajo y recursos
 ↳ naturales.
- 8 Aunque algunos lo critiquen, el intermediario es necesario en la
 ↳ economía.
- 9 El impuesto sobre los
 ↳ intereses es una forma efectiva de medir el valor de las rentas y la riqueza
 ↳ del país.

```
[16]: if str(PROJECT_ROOT) not in sys.path:
      sys.path.append(str(PROJECT_ROOT))

      from src.evaluation.metrics import evaluate_dataframe, summarize_metrics

      print("Módulo src.evaluation.metrics importado correctamente.")
```

```
/home/harielpadillasanchez/Documentos/TT/TT2/.venv-bloom/lib/python3.10/site-
packages/tqdm/auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
    from .autonotebook import tqdm as notebook_tqdm

Módulo src.evaluation.metrics importado correctamente.
```

```
[17]: df_for_metrics = qual_detail[
      [
          "sample36_id",
          "texto_eval_id",
          "system_name",
          "system_family",
          "source_text",
          "reference_text",
          "generated_text",
```

```

    ]
].copy()

print("df_for_metrics shape:", df_for_metrics.shape)
display(df_for_metrics.head())

df_quant_detail = evaluate_dataframe(
    df_for_metrics,
    source_col="source_text",
    pred_col="generated_text",
    ref_col="reference_text",
    compute_bertscore=COMPUTE_BERTSCORE,
    compute_sbent=False,
    bertscore_lang="es",
    bertscore_model_type=None,
)

print("df_quant_detail shape:", df_quant_detail.shape)
display(df_quant_detail.head())

```

df_for_metrics shape: (216, 7)

	sample36_id	texto_eval_id	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1

	system_family \
0	prompting
1	prompting
2	prompting
3	prompting
4	prompting

```

↪
↪source_text \
0
↪tiene incentivos ni motivación, dos elementos esenciales en ambientes de
↪competencia.
1 En los procesos de importaciones y exportaciones intervienen, además de
↪clientes y proveedores, instituciones del Estado y los bancos, tal como se
↪indica en...
2 El robo de identidad ocurre cuando su información personal, tal como su
↪nombre, número de cuenta, o número de cédula de identidad se usan sin su
↪conocimient...

```

3 Los sueños de los niños
 tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por Superman.

4 Expresiones como soborno y cohecho se refieren a
 ilícitos vinculados a la compra de la voluntad de un individuo para provecho personal.

reference_text \

0 No tiene sentido ni motivación. Estos elementos son esenciales para la competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones. También lo hacen las instituciones estatales y los banco como se indica a continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre, número de cuenta, o número de cédula de identidad se usan sin su conocimiento par...

3 Los
 sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y Superman.

4 Expresiones como soborno y cohecho se
 refieren a delitos vinculados a comprar la voluntad de alguien para provecho personal.

generated_text

0 Sin
 motivación y sin incentivos no se puede trabajar bien en un ambiente competitivo.

1 En la importación y exportación, también
 participan instituciones gubernamentales y bancos, como se muestra a continuación.

2 El robo de identidad es cuando alguien utiliza tu información personal, como tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer...

3 Los niños soñan con cosas como ser Tarzán, el Agente 007 o Superman.

4 Expresiones como "soborno" y "cohecho" se refieren a actos ilegales que involucran comprar el apoyo o consentimiento de alguien para beneficio propio.

df_quant_detail shape: (216, 32)

	sample36_id	texto_eval_id	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1

	system_family \
0	prompting
1	prompting
2	prompting
3	prompting
4	prompting

↪

↪source_text \

0 No

↪tiene incentivos ni motivación, dos elementos esenciales en ambientes de

↪competencia.

1 En los procesos de importaciones y exportaciones intervienen, además de

↪clientes y proveedores, instituciones del Estado y los bancos, tal como se

↪indica en...

2 El robo de identidad ocurre cuando su información personal, tal como su

↪nombre, número de cuenta, o número de cédula de identidad se usan sin su

↪conocimiento...

3 Los sueños de los niños

↪tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por

↪Superman.

4 Expresiones como soborno y cohecho se refieren a

↪ilícitos vinculados a la compra de la voluntad de un individuo para provecho

↪personal.

↪

↪reference_text \

0

↪No tiene sentido ni motivación. Estos elementos son esenciales para la

↪competencia.

1 Clientes y proveedores intervienen en las importaciones y exportaciones.

↪También lo hacen las instituciones estatales y los banco como se indica a

↪continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre,

↪número de cuenta, o número de cédula de identidad se usan sin su conocimiento

↪par...

3 Los
 ↳sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y
 ↳Superman.

4 Expresiones como soborno y cohecho se
 ↳refieren a delitos vinculados a comprar la voluntad de alguien para provecho
 ↳personal.

↳

↳generated_text \

0 Sin
 ↳motivación y sin incentivos no se puede trabajar bien en un ambiente
 ↳competitivo.

1 En la importación y exportación, también
 ↳participan instituciones gubernamentales y bancos, como se muestra a
 ↳continuación.

2 El robo de identidad es cuando alguien utiliza tu información personal, como
 ↳tu nombre y números de cuenta o cédula de identidad, sin tu permiso para hacer
 ↳...

3 Los niños soñan con cosas como ser Tarzán, el Agente 007 o
 ↳Superman.

4 Expresiones como "soborno" y "cohecho" se refieren a actos ilegales
 ↳que involucran comprar el apoyo o consentimiento de alguien para beneficio
 ↳propio.

	src_words	pred_words	ref_words	src_sentences	pred_sentences	\
0	12	14	12	1	1	
1	27	16	23	1	1	
2	33	29	32	1	1	
3	20	13	17	1	1	
4	22	22	19	1	1	

	ref_sentences	sari	bleu	fernandez_huerta_pred	\
0	2	32.203642	3.125191	75.268571	
1	2	39.978437	4.965502	46.715000	
2	1	17.341470	13.523512	72.977931	
3	1	39.355610	11.326623	102.070769	
4	1	39.102538	11.145672	60.385455	

	fernandez_huerta_src	fernandez_huerta_delta	compression_ratio_eval	\
0	48.340000	26.928571	1.166667	
1	69.728889	-23.013889	0.592593	
2	81.930909	-8.952978	0.878788	
3	99.740000	2.330769	0.650000	
4	68.567273	-8.181818	1.000000	

	sentence_splits	levenshtein_similarity	exact_copy	additions_proportion	\
0	0	0.485549	0	0.714286	
1	0	0.516556	0	0.562500	
2	0	0.717391	0	0.413793	
3	0	0.536313	0	0.461538	
4	0	0.582456	0	0.545455	

	deletions_proportion	inflesz_pred	inflesz_src	inflesz_delta	rouge1_f	\
0	0.666667	63.785000	39.085000	24.700000	0.214286	
1	0.740741	31.191250	41.390556	-10.199306	0.488889	
2	0.484848	42.493621	47.347121	-4.853501	0.588235	
3	0.650000	93.196538	80.925000	12.271538	0.500000	
4	0.545455	37.580455	46.075909	-8.495455	0.585366	

	rouge2_f	rougeL_f	bertscore_f1	sbert_similarity
0	0.076923	0.142857	0.744898	None
1	0.186047	0.488889	0.814797	None
2	0.333333	0.588235	0.854182	None
3	0.294118	0.500000	0.842181	None
4	0.461538	0.585366	0.895930	None

```
[18]: available_metrics = []
missing_metrics = []

for metric in QUANT_METRICS:
    if metric in df_quant_detail.columns and df_quant_detail[metric].notna().
    any():
        available_metrics.append(metric)
    else:
        missing_metrics.append(metric)

print("Métricas disponibles:")
for m in available_metrics:
    print("-", m)

print("\nMétricas NO disponibles:")
for m in missing_metrics:
    print("-", m)

if missing_metrics:
    print("\nSi faltan BLEU o ROUGE, ejecuta la celda de instalación y vuelve a
    ↪correr desde la importación de métricas.")
    print("Si falta BERTScore, verifica que bert-score esté instalado o cambia
    ↪COMPUTE_BERTSCORE.")
```

Métricas disponibles:

- sari
- bleu

- bertscore_f1
- rouge1_f
- rouge2_f
- rougeL_f
- fernandez_huerta_pred
- fernandez_huerta_src
- fernandez_huerta_delta
- inflesz_pred
- inflesz_src
- inflesz_delta
- compression_ratio_eval
- sentence_splits
- levenshtein_similarity
- exact_copy
- additions_proportion
- deletions_proportion

Métricas NO disponibles:

```
[19]: for col in QUAL_SCORE_COLS:
        qual_detail[col] = pd.to_numeric(qual_detail[col], errors="coerce")

print("Valores faltantes por criterio:")
display(qual_detail[QUAL_SCORE_COLS].isna().sum())

rows_missing = qual_detail[qual_detail[QUAL_SCORE_COLS].isna().any(axis=1)]

print("Filas con algún criterio faltante:", len(rows_missing))

if len(rows_missing) > 0:
    display(
        rows_missing[
            [
                "texto_eval_id",
                "sample36_id",
                "system_name",
            ] + QUAL_SCORE_COLS
        ].head(20)
    )
```

Valores faltantes por criterio:

score_fidelidad	0
score_comprension	0
score_fluidez	0
score_lexico	0
score_tono	0
score_estructura	0
score_numeros	2

dtype: int64

Filas con algún criterio faltante: 2

	texto_eval_id	sample36_id	\
128	129	21	
141	142	34	

	system_name	score_fidelidad	\
128	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	5.0	
141	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	3.0	

	score_comprension	score_fluidez	score_lexico	score_tono	\
128	5.0	3.0	5.0	5.0	
141	5.0	5.0	5.0	5.0	

	score_estructura	score_numeros
128	5.0	NaN
141	5.0	NaN

```
[20]: qual_detail["aplico_regla_cero"] = (qual_detail[QUAL_SCORE_COLS] == 0).
      ↪any(axis=1)

weight_sum = sum(QUAL_WEIGHTS.values())

qual_detail["score_cualitativo_1_5_sin_regla_cero"] = 0.0

for col, weight in QUAL_WEIGHTS.items():
    qual_detail["score_cualitativo_1_5_sin_regla_cero"] += (
        qual_detail[col] * (weight / weight_sum)
    )

qual_detail["score_cualitativo_1_5"] = np.where(
    qual_detail["aplico_regla_cero"],
    0.0,
    qual_detail["score_cualitativo_1_5_sin_regla_cero"]
)

qual_detail["score_cualitativo_100"] = (qual_detail["score_cualitativo_1_5"] /
      ↪5.0) * 100.0

display(
    qual_detail[
        [
            "sample36_id",
            "texto_eval_id",
            "system_name",
            "aplico_regla_cero",
```

```
        "score_cualitativo_1_5",
        "score_cualitativo_100",
    ] + QUAL_SCORE_COLS
].head(15)
)
```

	sample36_id	texto_eval_id	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1
5	6	6	few-shot_hariel_llama3_llama3_cfg_3_R1
6	7	7	few-shot_hariel_llama3_llama3_cfg_3_R1
7	8	8	few-shot_hariel_llama3_llama3_cfg_3_R1
8	9	9	few-shot_hariel_llama3_llama3_cfg_3_R1
9	10	10	few-shot_hariel_llama3_llama3_cfg_3_R1
10	11	11	few-shot_hariel_llama3_llama3_cfg_3_R1
11	12	12	few-shot_hariel_llama3_llama3_cfg_3_R1
12	13	13	few-shot_hariel_llama3_llama3_cfg_3_R1
13	14	14	few-shot_hariel_llama3_llama3_cfg_3_R1
14	15	15	few-shot_hariel_llama3_llama3_cfg_3_R1

	aplico_regla_cero	score_cualitativo_1_5	score_cualitativo_100 \
0	False	5.0	100.0
1	False	5.0	100.0
2	False	5.0	100.0
3	False	4.1	82.0
4	False	5.0	100.0
5	False	5.0	100.0
6	False	5.0	100.0
7	False	4.3	86.0
8	False	5.0	100.0
9	False	5.0	100.0
10	False	5.0	100.0
11	False	5.0	100.0
12	False	5.0	100.0
13	False	4.7	94.0
14	False	5.0	100.0

	score_fidelidad	score_comprension	score_fluidez	score_lexico \
0	5.0	5.0	5.0	5.0
1	5.0	5.0	5.0	5.0
2	5.0	5.0	5.0	5.0
3	5.0	3.0	5.0	1.0
4	5.0	5.0	5.0	5.0
5	5.0	5.0	5.0	5.0
6	5.0	5.0	5.0	5.0

7	5.0	3.0	5.0	5.0
8	5.0	5.0	5.0	5.0
9	5.0	5.0	5.0	5.0
10	5.0	5.0	5.0	5.0
11	5.0	5.0	5.0	5.0
12	5.0	5.0	5.0	5.0
13	5.0	5.0	3.0	5.0
14	5.0	5.0	5.0	5.0

	score_tono	score_estructura	score_numeros
0	5.0	5.0	5.0
1	5.0	5.0	5.0
2	5.0	5.0	5.0
3	5.0	5.0	5.0
4	5.0	5.0	5.0
5	5.0	5.0	5.0
6	5.0	5.0	5.0
7	5.0	3.0	5.0
8	5.0	5.0	5.0
9	5.0	5.0	5.0
10	5.0	5.0	5.0
11	5.0	5.0	5.0
12	5.0	5.0	5.0
13	5.0	5.0	5.0
14	5.0	5.0	5.0

```
[21]: qual_summary = (
    qual_detail
    .groupby(["system_name", "system_family"], as_index=False)
    .agg(
        n_textos_cualitativos=("sample36_id", "count"),
        score_cualitativo_promedio_1_5=("score_cualitativo_1_5", "mean"),
        score_cualitativo_mediano_1_5=("score_cualitativo_1_5", "median"),
        score_cualitativo_min_1_5=("score_cualitativo_1_5", "min"),
        score_cualitativo_max_1_5=("score_cualitativo_1_5", "max"),
        score_cualitativo_promedio_100=("score_cualitativo_100", "mean"),
        textos_con_regla_cero=("aplico_regla_cero", "sum"),
        promedio_fidelidad=("score_fidelidad", "mean"),
        promedio_comprension=("score_comprension", "mean"),
        promedio_fluidez=("score_fluidez", "mean"),
        promedio_lexico=("score_lexico", "mean"),
        promedio_tono=("score_tono", "mean"),
        promedio_estructura=("score_estructura", "mean"),
        promedio_numeros=("score_numeros", "mean"),
    )
)
```

```

qual_summary = qual_summary.sort_values(
    "score_cualitativo_promedio_100",
    ascending=False
).reset_index(drop=True)

qual_summary["rank_cualitativo"] = np.arange(1, len(qual_summary) + 1)

display(qual_summary)

```

	system_name	system_family	\
0	lora_mistral	lora	
1	lora_llama3	lora	
2	few-shot_hariel_llama3_llama3_cfg_3_R1	prompting	
3	few-shot_nancy_llama3_llama3_cfg_2_R2	prompting	
4	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	prompting	
5	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	prompting	

	n_textos_cualitativos	score_cualitativo_promedio_1_5	\
0	36	4.911111	
1	36	4.880556	
2	36	4.463889	
3	36	4.152778	
4	36	2.844444	
5	36	2.402941	

	score_cualitativo_mediano_1_5	score_cualitativo_min_1_5	\
0	5.00	4.5	
1	5.00	3.5	
2	5.00	1.0	
3	4.50	0.0	
4	3.90	0.0	
5	3.25	0.0	

	score_cualitativo_max_1_5	score_cualitativo_promedio_100	\
0	5.0	98.222222	
1	5.0	97.611111	
2	5.0	89.277778	
3	5.0	83.055556	
4	5.0	56.888889	
5	5.0	48.058824	

	textos_con_regla_cero	promedio_fidelidad	promedio_comprension	\
0	0	4.777778	5.000000	
1	0	4.666667	4.888889	
2	0	4.555556	4.388889	
3	1	3.750000	4.027778	
4	12	2.500000	2.888889	
5	15	2.472222	2.527778	

	promedio_fluidez	promedio_lexico	promedio_tono	promedio_estructura \
0	4.944444	4.833333	4.944444	5.000000
1	5.000000	5.000000	5.000000	4.944444
2	4.444444	4.444444	4.555556	4.388889
3	4.361111	4.527778	4.527778	4.416667
4	2.833333	2.944444	3.166667	2.944444
5	2.250000	2.694444	2.583333	2.694444

	promedio_numeros	rank_cualitativo
0	4.944444	1
1	4.944444	2
2	4.444444	3
3	4.138889	4
4	3.333333	5
5	2.676471	6

```
[22]: def mean_numeric(series):
    series = pd.to_numeric(series, errors="coerce")
    if series.notna().any():
        return series.mean()
    return np.nan

quant_summary = (
    df_quant_detail
    .groupby(["system_name", "system_family"], as_index=False)
    .agg(
        n_textos=("sample36_id", "count"),
        **{metric: (metric, mean_numeric) for metric in QUANT_METRICS}
    )
)

# Leader score:
# 60% SARI + 40% BERTScore_F1 en escala 0-100.
# Si BERTScore no existe, se usa solo SARI para evitar NaN.
if "bertscore_f1" in quant_summary.columns and quant_summary["bertscore_f1"].
    notna().any():
    quant_summary["leader_score"] = (
        0.60 * quant_summary["sari"] +
        0.40 * (quant_summary["bertscore_f1"] * 100.0)
    )
else:
    quant_summary["leader_score"] = quant_summary["sari"]

quant_summary = quant_summary.sort_values(
    ["leader_score", "sari"],
```

```

        ascending=False
    ).reset_index(drop=True)

    quant_summary["rank_leader_score"] = np.arange(1, len(quant_summary) + 1)

    display(quant_summary)

```

	system_name	system_family	n_textos	\
0	lora_llama3	lora	36	
1	lora_mistral	lora	36	
2	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	prompting	36	
3	few-shot_nancy_llama3_llama3_cfg_2_R2	prompting	36	
4	few-shot_hariel_llama3_llama3_cfg_3_R1	prompting	36	
5	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	prompting	36	

	sari	bleu	bertscore_f1	rouge1_f	rouge2_f	rougeL_f	\
0	45.340000	43.802869	0.895692	0.716483	0.578017	0.686885	
1	41.176172	41.995827	0.891969	0.709323	0.572314	0.679365	
2	36.889493	13.618780	0.793498	0.427987	0.228261	0.373693	
3	35.376242	13.077614	0.808004	0.420103	0.221107	0.371417	
4	34.720050	12.621101	0.807067	0.409761	0.218861	0.376495	
5	34.354454	10.494575	0.785960	0.401170	0.189632	0.359806	

	fernandez_huerta_pred	fernandez_huerta_src	fernandez_huerta_delta	\
0	72.747078	81.010563	-8.263485	
1	75.652359	81.010563	-5.358203	
2	73.975601	81.010563	-7.034962	
3	73.498114	81.010563	-7.512449	
4	71.983624	81.010563	-9.026939	
5	76.329574	81.010563	-4.680989	

	inflesz_pred	inflesz_src	inflesz_delta	compression_ratio_eval	\
0	62.053944	59.599136	2.454807	0.835316	
1	63.510643	59.599136	3.911507	0.868639	
2	64.159996	59.599136	4.560859	1.200421	
3	60.521654	59.599136	0.922518	0.914333	
4	59.856422	59.599136	0.257286	1.062598	
5	66.617159	59.599136	7.018022	1.111977	

	sentence_splits	levenshtein_similarity	exact_copy	additions_proportion	\
0	0.277778	0.811545	0.138889	0.063352	
1	0.250000	0.820872	0.194444	0.062510	
2	0.750000	0.436021	0.000000	0.567748	
3	0.083333	0.470420	0.000000	0.528829	
4	0.166667	0.468635	0.000000	0.549375	
5	0.638889	0.409169	0.000000	0.577812	

deletions_proportion leader_score rank_leader_score

0	0.221930	63.031661	1
1	0.181661	60.384444	2
2	0.563793	53.873632	3
3	0.626821	53.545895	4
4	0.645109	53.114721	5
5	0.588345	52.051082	6

```
[23]: # Métricas donde más alto es mejor.
HIGHER_IS_BETTER = [
    "sari",
    "bleu",
    "bertscore_f1",
    "rouge1_f",
    "rouge2_f",
    "rougeL_f",
    "fernandez_huerta_pred",
    "inflesz_pred",
]

# Métricas donde más bajo es mejor.
LOWER_IS_BETTER = [
    "exact_copy",
]

# Métricas donde se busca cercanía a un valor objetivo.
TARGET_IS_BETTER = {
    "compression_ratio_eval": COMPRESSION_TARGET,
}

# Métricas que se reportan, pero no entran directamente al score integral
# porque su interpretación depende del caso.
DESCRIPTIVE_ONLY = [
    "fernandez_huerta_src",
    "fernandez_huerta_delta",
    "inflesz_src",
    "inflesz_delta",
    "sentence_splits",
    "levenshtein_similarity",
    "additions_proportion",
    "deletions_proportion",
]

def minmax_normalize(series: pd.Series, higher_is_better=True):
    s = pd.to_numeric(series, errors="coerce")

    if not s.notna().any():
```

```

        return pd.Series(np.nan, index=s.index)

    min_val = s.min()
    max_val = s.max()

    if np.isclose(min_val, max_val):
        return pd.Series(1.0, index=s.index)

    norm = (s - min_val) / (max_val - min_val)

    if not higher_is_better:
        norm = 1 - norm

    return norm

def target_normalize(series: pd.Series, target: float):
    s = pd.to_numeric(series, errors="coerce")

    if not s.notna().any():
        return pd.Series(np.nan, index=s.index)

    distance = (s - target).abs()
    return minmax_normalize(distance, higher_is_better=False)

```

```

[24]: quant_norm = quant_summary.copy()

norm_cols = []

for metric in HIGHER_IS_BETTER:
    if metric in quant_norm.columns and quant_norm[metric].notna().any():
        col = f"norm_{metric}"
        quant_norm[col] = minmax_normalize(quant_norm[metric],
↪higher_is_better=True)
        norm_cols.append(col)

for metric in LOWER_IS_BETTER:
    if metric in quant_norm.columns and quant_norm[metric].notna().any():
        col = f"norm_{metric}"
        quant_norm[col] = minmax_normalize(quant_norm[metric],
↪higher_is_better=False)
        norm_cols.append(col)

for metric, target in TARGET_IS_BETTER.items():
    if metric in quant_norm.columns and quant_norm[metric].notna().any():
        col = f"norm_{metric}"
        quant_norm[col] = target_normalize(quant_norm[metric], target=target)

```

```

        norm_cols.append(col)

quant_norm["norm_leader_score"] = minmax_normalize(
    quant_norm["leader_score"],
    higher_is_better=True
)

# Promedio de métricas auxiliares.
aux_norm_cols = norm_cols.copy()

quant_norm["aux_quant_score"] = quant_norm[aux_norm_cols].mean(axis=1,
    ↪ skipna=True)

# Score cuantitativo integral:
# 50% leader score normalizado + 50% resto de métricas normalizadas.
quant_norm["score_cuantitativo_integral_100"] = (
    0.50 * quant_norm["norm_leader_score"] +
    0.50 * quant_norm["aux_quant_score"]
) * 100

quant_score_df = quant_norm.sort_values(
    "score_cuantitativo_integral_100",
    ascending=False
).reset_index(drop=True)

quant_score_df["rank_cuantitativo_integral"] = np.arange(1, len(quant_score_df),
    ↪ + 1)

print("Métricas normalizadas usadas para el score cuantitativo:")
for c in aux_norm_cols:
    print("-", c)

display(
    quant_score_df[
        [
            "system_name",
            "system_family",
            "n_textos",
            "leader_score",
            "score_cuantitativo_integral_100",
            "rank_cuantitativo_integral",
        ] + QUANT_METRICS
    ]
)

```

Métricas normalizadas usadas para el score cuantitativo:

- norm_sari

- norm_bleu
- norm_bertscore_f1
- norm_rouge1_f
- norm_rouge2_f
- norm_rougeL_f
- norm_fernandez_huerta_pred
- norm_inflesz_pred
- norm_exact_copy
- norm_compression_ratio_eval

	system_name	system_family	n_textos	\
0	lora_llama3	lora	36	
1	lora_mistral	lora	36	
2	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	prompting	36	
3	few-shot_nancy_llama3_llama3_cfg_2_R2	prompting	36	
4	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	prompting	36	
5	few-shot_hariel_llama3_llama3_cfg_3_R1	prompting	36	

	leader_score	score_cuantitativo_integral_100	rank_cuantitativo_integral	\
0	63.031661	88.932132	1	
1	60.384444	77.172457	2	
2	53.873632	21.874626	3	
3	53.545895	21.041775	4	
4	52.051082	16.317162	5	
5	53.114721	14.110853	6	

	sari	bleu	bertscore_f1	rouge1_f	rouge2_f	rougeL_f	\
0	45.340000	43.802869	0.895692	0.716483	0.578017	0.686885	
1	41.176172	41.995827	0.891969	0.709323	0.572314	0.679365	
2	36.889493	13.618780	0.793498	0.427987	0.228261	0.373693	
3	35.376242	13.077614	0.808004	0.420103	0.221107	0.371417	
4	34.354454	10.494575	0.785960	0.401170	0.189632	0.359806	
5	34.720050	12.621101	0.807067	0.409761	0.218861	0.376495	

	fernandez_huerta_pred	fernandez_huerta_src	fernandez_huerta_delta	\
0	72.747078	81.010563	-8.263485	
1	75.652359	81.010563	-5.358203	
2	73.975601	81.010563	-7.034962	
3	73.498114	81.010563	-7.512449	
4	76.329574	81.010563	-4.680989	
5	71.983624	81.010563	-9.026939	

	inflesz_pred	inflesz_src	inflesz_delta	compression_ratio_eval	\
0	62.053944	59.599136	2.454807	0.835316	
1	63.510643	59.599136	3.911507	0.868639	
2	64.159996	59.599136	4.560859	1.200421	
3	60.521654	59.599136	0.922518	0.914333	
4	66.617159	59.599136	7.018022	1.111977	

5	59.856422	59.599136	0.257286	1.062598
---	-----------	-----------	----------	----------

	sentence_splits	levenshtein_similarity	exact_copy	additions_proportion \
0	0.277778	0.811545	0.138889	0.063352
1	0.250000	0.820872	0.194444	0.062510
2	0.750000	0.436021	0.000000	0.567748
3	0.083333	0.470420	0.000000	0.528829
4	0.638889	0.409169	0.000000	0.577812
5	0.166667	0.468635	0.000000	0.549375

	deletions_proportion
0	0.221930
1	0.181661
2	0.563793
3	0.626821
4	0.588345
5	0.645109

```
[25]: integral_df = quant_score_df.merge(
    qual_summary,
    on=["system_name", "system_family"],
    how="left"
)

missing_qual = integral_df[integral_df["score_cualitativo_promedio_100"].isna()]

print("integral_df shape:", integral_df.shape)

if len(missing_qual) > 0:
    print("Sistemas sin evaluación cualitativa:")
    display(missing_qual[["system_name", "system_family"]])
else:
    print("OK: todos los sistemas tienen evaluación cualitativa.")

display(integral_df.head())
```

integral_df shape: (6, 52)

OK: todos los sistemas tienen evaluación cualitativa.

	system_name	system_family	n_textos \
0	lora_llama3	lora	36
1	lora_mistral	lora	36
2	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	prompting	36
3	few-shot_nancy_llama3_llama3_cfg_2_R2	prompting	36
4	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	prompting	36

	sari	bleu	bertscore_f1	rouge1_f	rouge2_f	rougeL_f \
0	45.340000	43.802869	0.895692	0.716483	0.578017	0.686885
1	41.176172	41.995827	0.891969	0.709323	0.572314	0.679365

2	36.889493	13.618780	0.793498	0.427987	0.228261	0.373693
3	35.376242	13.077614	0.808004	0.420103	0.221107	0.371417
4	34.354454	10.494575	0.785960	0.401170	0.189632	0.359806

	fernandez_huerta_pred	fernandez_huerta_src	fernandez_huerta_delta	\
0	72.747078	81.010563	-8.263485	
1	75.652359	81.010563	-5.358203	
2	73.975601	81.010563	-7.034962	
3	73.498114	81.010563	-7.512449	
4	76.329574	81.010563	-4.680989	

	inflesz_pred	inflesz_src	inflesz_delta	compression_ratio_eval	\
0	62.053944	59.599136	2.454807	0.835316	
1	63.510643	59.599136	3.911507	0.868639	
2	64.159996	59.599136	4.560859	1.200421	
3	60.521654	59.599136	0.922518	0.914333	
4	66.617159	59.599136	7.018022	1.111977	

	sentence_splits	levenshtein_similarity	exact_copy	additions_proportion	\
0	0.277778	0.811545	0.138889	0.063352	
1	0.250000	0.820872	0.194444	0.062510	
2	0.750000	0.436021	0.000000	0.567748	
3	0.083333	0.470420	0.000000	0.528829	
4	0.638889	0.409169	0.000000	0.577812	

	deletions_proportion	leader_score	rank_leader_score	norm_sari	\
0	0.221930	63.031661	1	1.000000	
1	0.181661	60.384444	2	0.620972	
2	0.563793	53.873632	3	0.230761	
3	0.626821	53.545895	4	0.093012	
4	0.588345	52.051082	6	0.000000	

	norm_bleu	norm_bertscore_f1	norm_rouge1_f	norm_rouge2_f	norm_rougeL_f	\
0	1.000000	1.000000	1.000000	1.000000	1.000000	
1	0.945748	0.966072	0.977293	0.985314	0.977010	
2	0.093797	0.068697	0.085050	0.099462	0.042458	
3	0.077549	0.200886	0.060046	0.081041	0.035499	
4	0.000000	0.000000	0.000000	0.000000	0.000000	

	norm_fernandez_huerta_pred	norm_inflesz_pred	norm_exact_copy	\
0	0.175670	0.325042	0.285714	
1	0.844173	0.540506	0.000000	
2	0.458353	0.636554	1.000000	
3	0.348483	0.098396	1.000000	
4	1.000000	1.000000	1.000000	

	norm_compression_ratio_eval	norm_leader_score	aux_quant_score	\
0	1.000000	1.000000	0.778643	

1	0.988220	0.758918	0.784531
2	0.000000	0.165979	0.271513
3	0.852118	0.136132	0.284703
4	0.263432	0.000000	0.326343

	score_cuantitativo_integral_100	rank_cuantitativo_integral	\
0	88.932132		1
1	77.172457		2
2	21.874626		3
3	21.041775		4
4	16.317162		5

	n_textos_cualitativos	score_cualitativo_promedio_1_5	\
0	36	4.880556	
1	36	4.911111	
2	36	2.844444	
3	36	4.152778	
4	36	2.402941	

	score_cualitativo_mediano_1_5	score_cualitativo_min_1_5	\
0	5.00	3.5	
1	5.00	4.5	
2	3.90	0.0	
3	4.50	0.0	
4	3.25	0.0	

	score_cualitativo_max_1_5	score_cualitativo_promedio_100	\
0	5.0	97.611111	
1	5.0	98.222222	
2	5.0	56.888889	
3	5.0	83.055556	
4	5.0	48.058824	

	textos_con_regla_cero	promedio_fidelidad	promedio_comprension	\
0	0	4.666667	4.888889	
1	0	4.777778	5.000000	
2	12	2.500000	2.888889	
3	1	3.750000	4.027778	
4	15	2.472222	2.527778	

	promedio_fluidez	promedio_lexico	promedio_tono	promedio_estructura	\
0	5.000000	5.000000	5.000000	4.944444	
1	4.944444	4.833333	4.944444	5.000000	
2	2.833333	2.944444	3.166667	2.944444	
3	4.361111	4.527778	4.527778	4.416667	
4	2.250000	2.694444	2.583333	2.694444	

	promedio_numeros	rank_cualitativo
--	------------------	------------------

0	4.944444	2
1	4.944444	1
2	3.333333	5
3	4.138889	4
4	2.676471	6

```
[26]: integral_df["score_final_integral_100"] = (
    WEIGHT_QUANT * integral_df["score_cuantitativo_integral_100"] +
    WEIGHT_QUAL * integral_df["score_cualitativo_promedio_100"]
)

integral_df = integral_df.sort_values(
    "score_final_integral_100",
    ascending=False
).reset_index(drop=True)

integral_df["rank_final_integral"] = np.arange(1, len(integral_df) + 1)

main_cols = [
    "rank_final_integral",
    "system_name",
    "system_family",
    "n_textos",
    "n_textos_cualitativos",
    "leader_score",
    "score_cuantitativo_integral_100",
    "score_cualitativo_promedio_100",
    "score_final_integral_100",
    "rank_cuantitativo_integral",
    "rank_cualitativo",
    "textos_con_regla_cero",
]

display(integral_df[main_cols])
```

	rank_final_integral		system_name \
0	1		lora_llama3
1	2		lora_mistral
2	3	few-shot_nancy_llama3_llama3_cfg_2_R2	
3	4	few-shot_hariel_llama3_llama3_cfg_3_R1	
4	5	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	
5	6	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	

	system_family	n_textos	n_textos_cualitativos	leader_score \
0	lora	36	36	63.031661
1	lora	36	36	60.384444
2	prompting	36	36	53.545895
3	prompting	36	36	53.114721

4	prompting	36	36	53.873632
5	prompting	36	36	52.051082

	score_cuantitativo_integral_100	score_cualitativo_promedio_100	\
0	88.932132	97.611111	
1	77.172457	98.222222	
2	21.041775	83.055556	
3	14.110853	89.277778	
4	21.874626	56.888889	
5	16.317162	48.058824	

	score_final_integral_100	rank_cuantitativo_integral	rank_cualitativo	\
0	93.271621	1	2	
1	87.697339	2	1	
2	52.048665	4	4	
3	51.694316	6	3	
4	39.381757	3	5	
5	32.187993	5	6	

	textos_con_regla_cero
0	0
1	0
2	1
3	0
4	12
5	15

```
[27]: report_cols = [
    "rank_final_integral",
    "system_name",
    "system_family",
    "n_textos",
    "leader_score",
    "score_cuantitativo_integral_100",
    "score_cualitativo_promedio_100",
    "score_final_integral_100",
    "rank_cuantitativo_integral",
    "rank_cualitativo",
    "textos_con_regla_cero",
] + QUANT_METRICS + [
    "score_cualitativo_promedio_1_5",
    "score_cualitativo_mediano_1_5",
    "score_cualitativo_min_1_5",
    "score_cualitativo_max_1_5",
    "promedio_fidelidad",
    "promedio_comprension",
    "promedio_fluidez",
```

```

    "promedio_lexico",
    "promedio_tono",
    "promedio_estructura",
    "promedio_numeros",
]

report_cols = [c for c in report_cols if c in integral_df.columns]

df_reporte = integral_df[report_cols].copy()

display(df_reporte)

```

	rank_final_integral	system_name \
0	1	lora_llama3
1	2	lora_mistral
2	3	few-shot_nancy_llama3_llama3_cfg_2_R2
3	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4
5	6	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4

	system_family	n_textos	leader_score	score_cuantitativo_integral_100 \
0	lora	36	63.031661	88.932132
1	lora	36	60.384444	77.172457
2	prompting	36	53.545895	21.041775
3	prompting	36	53.114721	14.110853
4	prompting	36	53.873632	21.874626
5	prompting	36	52.051082	16.317162

	score_cualitativo_promedio_100	score_final_integral_100 \
0	97.611111	93.271621
1	98.222222	87.697339
2	83.055556	52.048665
3	89.277778	51.694316
4	56.888889	39.381757
5	48.058824	32.187993

	rank_cuantitativo_integral	rank_cualitativo	textos_con_regla_cero \
0	1	2	0
1	2	1	0
2	4	4	1
3	6	3	0
4	3	5	12
5	5	6	15

	sari	bleu	bertscore_f1	rouge1_f	rouge2_f	rougeL_f \
0	45.340000	43.802869	0.895692	0.716483	0.578017	0.686885
1	41.176172	41.995827	0.891969	0.709323	0.572314	0.679365
2	35.376242	13.077614	0.808004	0.420103	0.221107	0.371417

3	34.720050	12.621101	0.807067	0.409761	0.218861	0.376495
4	36.889493	13.618780	0.793498	0.427987	0.228261	0.373693
5	34.354454	10.494575	0.785960	0.401170	0.189632	0.359806

	fernandez_huerta_pred	fernandez_huerta_src	fernandez_huerta_delta	\
0	72.747078	81.010563	-8.263485	
1	75.652359	81.010563	-5.358203	
2	73.498114	81.010563	-7.512449	
3	71.983624	81.010563	-9.026939	
4	73.975601	81.010563	-7.034962	
5	76.329574	81.010563	-4.680989	

	inflesz_pred	inflesz_src	inflesz_delta	compression_ratio_eval	\
0	62.053944	59.599136	2.454807	0.835316	
1	63.510643	59.599136	3.911507	0.868639	
2	60.521654	59.599136	0.922518	0.914333	
3	59.856422	59.599136	0.257286	1.062598	
4	64.159996	59.599136	4.560859	1.200421	
5	66.617159	59.599136	7.018022	1.111977	

	sentence_splits	levenshtein_similarity	exact_copy	additions_proportion	\
0	0.277778	0.811545	0.138889	0.063352	
1	0.250000	0.820872	0.194444	0.062510	
2	0.083333	0.470420	0.000000	0.528829	
3	0.166667	0.468635	0.000000	0.549375	
4	0.750000	0.436021	0.000000	0.567748	
5	0.638889	0.409169	0.000000	0.577812	

	deletions_proportion	score_cualitativo_promedio_1_5	\
0	0.221930	4.880556	
1	0.181661	4.911111	
2	0.626821	4.152778	
3	0.645109	4.463889	
4	0.563793	2.844444	
5	0.588345	2.402941	

	score_cualitativo_mediano_1_5	score_cualitativo_min_1_5	\
0	5.00	3.5	
1	5.00	4.5	
2	4.50	0.0	
3	5.00	1.0	
4	3.90	0.0	
5	3.25	0.0	

	score_cualitativo_max_1_5	promedio_fidelidad	promedio_comprension	\
0	5.0	4.666667	4.888889	
1	5.0	4.777778	5.000000	
2	5.0	3.750000	4.027778	

3	5.0	4.555556	4.388889
4	5.0	2.500000	2.888889
5	5.0	2.472222	2.527778

	promedio_fluidez	promedio_lexico	promedio_tono	promedio_estructura \
0	5.000000	5.000000	5.000000	4.944444
1	4.944444	4.833333	4.944444	5.000000
2	4.361111	4.527778	4.527778	4.416667
3	4.444444	4.444444	4.555556	4.388889
4	2.833333	2.944444	3.166667	2.944444
5	2.250000	2.694444	2.583333	2.694444

	promedio_numeros
0	4.944444
1	4.944444
2	4.138889
3	4.444444
4	3.333333
5	2.676471

```
[28]: comparison_ranks = integral_df[
    [
        "system_name",
        "system_family",
        "rank_cuantitativo_integral",
        "rank_cualitativo",
        "rank_final_integral",
        "leader_score",
        "score_cuantitativo_integral_100",
        "score_cualitativo_promedio_100",
        "score_final_integral_100",
    ]
].copy()

comparison_ranks["diferencia_rank_cuant_vs_cual"] = (
    comparison_ranks["rank_cuantitativo_integral"] -
    comparison_ranks["rank_cualitativo"]
)

comparison_ranks["diferencia_rank_cuant_vs_final"] = (
    comparison_ranks["rank_cuantitativo_integral"] -
    comparison_ranks["rank_final_integral"]
)

display(comparison_ranks)
```

	system_name	system_family \
0	lora_llama3	lora

	lora_mistral	lora
1	few-shot_nancy_llama3_llama3_cfg_2_R2	prompting
2	few-shot_hariel_llama3_llama3_cfg_3_R1	prompting
3	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	prompting
4	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	prompting

	rank_cuantitativo_integral	rank_cualitativo	rank_final_integral \
0	1	2	1
1	2	1	2
2	4	4	3
3	6	3	4
4	3	5	5
5	5	6	6

	leader_score	score_cuantitativo_integral_100 \
0	63.031661	88.932132
1	60.384444	77.172457
2	53.545895	21.041775
3	53.114721	14.110853
4	53.873632	21.874626
5	52.051082	16.317162

	score_cualitativo_promedio_100	score_final_integral_100 \
0	97.611111	93.271621
1	98.222222	87.697339
2	83.055556	52.048665
3	89.277778	51.694316
4	56.888889	39.381757
5	48.058824	32.187993

	diferencia_rank_cuant_vs_cual	diferencia_rank_cuant_vs_final
0	-1	0
1	1	0
2	0	1
3	3	2
4	-2	-2
5	-1	-1

```
[29]: family_summary = (
    integral_df
    .groupby("system_family", as_index=False)
    .agg(
        n_sistemas=("system_name", "count"),
        leader_score_promedio=("leader_score", "mean"),
        score_cuantitativo_promedio=("score_cuantitativo_integral_100", "mean"),
        score_cualitativo_promedio=("score_cualitativo_promedio_100", "mean"),
        score_final_promedio=("score_final_integral_100", "mean"),
    )
)
```

```

        mejor_rank_final=("rank_final_integral", "min"),
    )
    .sort_values("score_final_promedio", ascending=False)
)

display(family_summary)

```

```

system_family  n_sistemas  leader_score_promedio  \
0          lora           2          61.708052
1    prompting           4          53.146333

score_cuantitativo_promedio  score_cualitativo_promedio  \
0              83.052294              97.916667
1              18.336104              69.320261

score_final_promedio  mejor_rank_final
0              90.484480              1
1              43.828183              3

```

```

[30]: detail_df = df_quant_detail.merge(
    qual_detail[
        [
            "sample36_id",
            "texto_eval_id",
            "system_name",
            "score_cualitativo_1_5",
            "score_cualitativo_100",
            "aplico_regla_cero",
        ] + QUAL_SCORE_COLS
    ],
    on=["sample36_id", "texto_eval_id", "system_name"],
    how="left"
)

print("detail_df shape:", detail_df.shape)

display(
    detail_df[
        [
            "sample36_id",
            "texto_eval_id",
            "system_name",
            "sari",
            "bleu",
            "bertscore_f1",
            "rougeL_f",
            "compression_ratio_eval",
        ]
    ]
)

```

```

        "exact_copy",
        "score_cualitativo_100",
    ]
].head(20)
)

```

detail_df shape: (216, 42)

	sample36_id	texto_eval_id	system_name \
0	1	1	few-shot_hariel_llama3_llama3_cfg_3_R1
1	2	2	few-shot_hariel_llama3_llama3_cfg_3_R1
2	3	3	few-shot_hariel_llama3_llama3_cfg_3_R1
3	4	4	few-shot_hariel_llama3_llama3_cfg_3_R1
4	5	5	few-shot_hariel_llama3_llama3_cfg_3_R1
5	6	6	few-shot_hariel_llama3_llama3_cfg_3_R1
6	7	7	few-shot_hariel_llama3_llama3_cfg_3_R1
7	8	8	few-shot_hariel_llama3_llama3_cfg_3_R1
8	9	9	few-shot_hariel_llama3_llama3_cfg_3_R1
9	10	10	few-shot_hariel_llama3_llama3_cfg_3_R1
10	11	11	few-shot_hariel_llama3_llama3_cfg_3_R1
11	12	12	few-shot_hariel_llama3_llama3_cfg_3_R1
12	13	13	few-shot_hariel_llama3_llama3_cfg_3_R1
13	14	14	few-shot_hariel_llama3_llama3_cfg_3_R1
14	15	15	few-shot_hariel_llama3_llama3_cfg_3_R1
15	16	16	few-shot_hariel_llama3_llama3_cfg_3_R1
16	17	17	few-shot_hariel_llama3_llama3_cfg_3_R1
17	18	18	few-shot_hariel_llama3_llama3_cfg_3_R1
18	19	19	few-shot_hariel_llama3_llama3_cfg_3_R1
19	20	20	few-shot_hariel_llama3_llama3_cfg_3_R1


	sari	bleu	bertscore_f1	rougeL_f	compression_ratio_eval \
0	32.203642	3.125191	0.744898	0.142857	1.166667
1	39.978437	4.965502	0.814797	0.488889	0.592593
2	17.341470	13.523512	0.854182	0.588235	0.878788
3	39.355610	11.326623	0.842181	0.500000	0.650000
4	39.102538	11.145672	0.895930	0.585366	1.000000
5	31.316305	3.458592	0.713971	0.333333	1.076923
6	75.090767	71.142773	0.947379	0.882353	0.885714
7	44.701809	10.285879	0.763732	0.355556	0.576923
8	61.030284	36.112253	0.925206	0.615385	0.687500
9	32.652860	15.450704	0.875254	0.434783	0.954545
10	49.687652	21.010047	0.768796	0.400000	0.520000
11	23.485703	2.166216	0.779009	0.274510	0.846154
12	35.419194	11.643948	0.818693	0.375000	0.761905
13	54.893146	37.415694	0.852815	0.600000	0.583333
14	36.576157	7.020663	0.779478	0.290323	0.581081
15	41.968972	9.246523	0.826532	0.387097	0.826087
16	34.348667	5.778324	0.762521	0.181818	0.696970

17	32.350278	3.461253	0.700379	0.190476	0.333333
18	32.509821	4.154664	0.796089	0.285714	1.160000
19	53.345960	41.113362	0.897315	0.625000	1.125000

	exact_copy	score_cualitativo_100
0	0	100.0
1	0	100.0
2	0	100.0
3	0	82.0
4	0	100.0
5	0	100.0
6	0	100.0
7	0	86.0
8	0	100.0
9	0	100.0
10	0	100.0
11	0	100.0
12	0	100.0
13	0	94.0
14	0	100.0
15	0	100.0
16	0	100.0
17	0	78.0
18	0	100.0
19	0	100.0

```
[31]: plot_df = integral_df.sort_values("score_final_integral_100", ascending=True)

plt.figure(figsize=(11, 5))
plt.barh(plot_df["system_name"], plot_df["score_final_integral_100"])
plt.xlabel("Score final integral (0-100)")
plt.ylabel("Sistema")
plt.title("Ranking integral: evaluación cuantitativa + cualitativa interna")
plt.tight_layout()
plt.show()
```

Rank	Sistema	Familia	Score final
1	lora_mistral	LoRA	93.27
2	lora_llama3	LoRA	87.70
3	few-shot_nancy_llama3_llama3_cfg_2_R2	Prompting	52.05
4	few-shot_hariel_llama3_llama3_cfg_3_R1	Prompting	51.69
5	zero-shot_hariel_mistral_hariel_mistral_cfg_1_R4	Prompting	39.38
6	zero-shot_nancy_mistral_nancy_mistral_cfg_2_R4	Prompting	32.19

El ranking final se obtuvo mediante un score integral que combina evaluación cuantitativa automática y evaluación cualitativa interna. Primero, se recalcularon todas las métricas automáticas consideradas en el trabajo: SARI, BLEU, BERTScore, ROUGE, Fernández-Huerta, INFLESZ, compression ratio, sentence splits, Levenshtein similarity, exact copy, additions proportion y deletions proportion.

Para el ordenamiento cuantitativo se usaron las métricas con interpretación direccional clara: SARI, BLEU, BERTScore, ROUGE-1, ROUGE-2, ROUGE-L, Fernández-Huerta del texto generado, INFLESZ del texto generado, exact copy y compression ratio. Las métricas restantes se conservaron como métricas descriptivas para el análisis.

Posteriormente, el score cuantitativo integral se combinó con el score cualitativo interno obtenido mediante rúbrica humana, usando una ponderación 50/50. Así, el ranking final no depende únicamente de métricas automáticas, sino también de la calidad evaluada manualmente.

```
[32]: plt.figure(figsize=(8, 6))


plt.scatter(
    integral_df["score_cuantitativo_integral_100"],
    integral_df["score_cualitativo_promedio_100"]
)
```

```

for _, row in integral_df.iterrows():
    plt.text(
        row["score_cuantitativo_integral_100"] + 0.3,
        row["score_cualitativo_promedio_100"] + 0.3,
        row["system_name"],
        fontsize=8
    )

plt.xlabel("Score cuantitativo integral (0-100)")
plt.ylabel("Score cualitativo interno (0-100)")
plt.title("Relación entre evaluación automática y evaluación humana interna")
plt.tight_layout()
plt.show()

```



```

[33]: integral_path = OUT_DIR / "ranking_integral_cuantitativo_cualitativo.csv"
reporte_path = OUT_DIR / "tabla_reporte_tt_integral.csv"
detalle_path = OUT_DIR / "detalle_216_cuantitativo_cualitativo.csv"
quant_detail_path = OUT_DIR / "detalle_216_metricas_cuantitativas.csv"
qual_detail_path = OUT_DIR / "detalle_216_cualitativa_interna.csv"
family_path = OUT_DIR / "resumen_por_familia.csv"

```

```

excel_path = OUT_DIR / "evaluacion_integral_lora_vs_hiperparametros.xlsx"

integral_df.to_csv(integral_path, index=False, encoding="utf-8-sig")
df_reporte.to_csv(reporte_path, index=False, encoding="utf-8-sig")
detail_df.to_csv(detalle_path, index=False, encoding="utf-8-sig")
df_quant_detail.to_csv(quant_detail_path, index=False, encoding="utf-8-sig")
qual_detail.to_csv(qual_detail_path, index=False, encoding="utf-8-sig")
family_summary.to_csv(family_path, index=False, encoding="utf-8-sig")

with pd.ExcelWriter(excel_path, engine="openpyxl") as writer:
    df_reporte.to_excel(writer, sheet_name="Ranking reporte TT", index=False)
    integral_df.to_excel(writer, sheet_name="Ranking integral", index=False)
    quant_summary.to_excel(writer, sheet_name="Resumen cuantitativo",
    ↪index=False)
    qual_summary.to_excel(writer, sheet_name="Resumen cualitativo", index=False)
    comparison_ranks.to_excel(writer, sheet_name="Comparacion rankings",
    ↪index=False)
    family_summary.to_excel(writer, sheet_name="LoRA vs Prompting", index=False)
    detail_df.to_excel(writer, sheet_name="Detalle 216", index=False)
    df_quant_detail.to_excel(writer, sheet_name="Metricas cuantitativas",
    ↪index=False)
    qual_detail.to_excel(writer, sheet_name="Cualitativa interna", index=False)

print("Archivos guardados:")
print("-", integral_path)
print("-", reporte_path)
print("-", detalle_path)
print("-", quant_detail_path)
print("-", qual_detail_path)
print("-", family_path)
print("-", excel_path)

```

Archivos guardados:

- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/ranking_integral_cuantitativo_cualitativo.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/tabla_reporte_tt_integral.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/detalle_216_cuantitativo_cualitativo.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/detalle_216_metricas_cuantitativas.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/detalle_216_cualitativa_interna.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/resumen_por_familia.csv
- /home/harielpadillasanchez/Documentos/TT/TT2/outputs/evaluacion_integral_lora_vs_hiperparametros/evaluacion_integral_lora_vs_hiperparametros.xlsx

```
[34]: # Verificar si hay sistemas con salidas generadas idénticas
pivot_gen = qual_detail.pivot_table(
    index="sample36_id",
    columns="system_name",
    values="generated_text",
    aggfunc="first"
)

comparisons = [
    (
        "few-shot_hariel_llama3_llama3_cfg_3_R1",
        "lora_llama3"
    ),
    (
        "few-shot_nancy_llama3_llama3_cfg_2_R2",
        "lora_mistral"
    ),
]

for a, b in comparisons:
    if a in pivot_gen.columns and b in pivot_gen.columns:
        same = (
            pivot_gen[a].fillna("").str.strip()
            ==
            pivot_gen[b].fillna("").str.strip()
        )
        print(f"{a} vs {b}")
        print("Textos idénticos:", same.sum(), "de", len(same))
        print("Porcentaje:", round(same.mean() * 100, 2), "%")
        print("-" * 80)
```

few-shot_hariel_llama3_llama3_cfg_3_R1 vs lora_llama3

Textos idénticos: 0 de 36

Porcentaje: 0.0 %

few-shot_nancy_llama3_llama3_cfg_2_R2 vs lora_mistral

Textos idénticos: 0 de 36

Porcentaje: 0.0 %

```
[35]: from pathlib import Path
import pandas as pd
import numpy as np
import re

FINAL_DIR = PROJECT_ROOT / "FINAL_COMPARACION_36"
ALL_SYSTEMS_FINAL = FINAL_DIR / "04_todos_los_sistemas_sample36.csv"
```

```

print("ALL_SYSTEMS_FINAL:", ALL_SYSTEMS_FINAL, "| existe:", ALL_SYSTEMS_FINAL.
↳exists())

df_final = pd.read_csv(ALL_SYSTEMS_FINAL)

def norm_text(x):
    if pd.isna(x):
        return ""
    x = str(x)
    x = x.replace("\n", " ").replace("\r", " ").replace("\t", " ")
    x = re.sub(r"\s+", " ", x).strip()
    return x

# =====
# 1) Textos LoRA usados desde el Excel interno
# =====
excel_lora_texts = qual_detail[
    qual_detail["system_family"] == "lora"
].copy()

excel_lora_texts["generated_text_norm"] = excel_lora_texts["generated_text"].
↳apply(norm_text)

print("\nLoRA desde Excel interno / qual_detail:")
display(
    excel_lora_texts[
        [
            "sample36_id",
            "texto_eval_id",
            "system_name",
            "source_text",
            "reference_text",
            "generated_text",
        ]
    ].head(10)
)

# =====
# 2) Textos LoRA reales desde FINAL_COMPARACION_36
# =====
final_lora_texts = df_final[
    df_final["system_name"].isin(["lora_llama3", "lora_mistral"])
].copy()

final_lora_texts = final_lora_texts.sort_values(["system_name", "row_id"]).
↳reset_index(drop=True)

```

```

final_lora_texts["sample36_id"] = (
    final_lora_texts.groupby("system_name").cumcount() + 1
)

final_lora_texts["generated_text_norm"] = final_lora_texts["generated_text"].
    ↪ apply(norm_text)

print("\nLoRA real desde FINAL_COMPARACION_36:")
display(
    final_lora_texts[
        [
            "sample36_id",
            "row_id",
            "system_name",
            "source_text",
            "reference_text",
            "generated_text",
        ]
    ].head(10)
)

# =====
# 3) Comparación Excel vs FINAL por sistema y posición
# =====
compare_lora = excel_lora_texts[
    [
        "sample36_id",
        "texto_eval_id",
        "system_name",
        "generated_text",
        "generated_text_norm",
    ]
].merge(
    final_lora_texts[
        [
            "sample36_id",
            "row_id",
            "system_name",
            "generated_text",
            "generated_text_norm",
        ]
    ],
    on=["sample36_id", "system_name"],
    how="left",
    suffixes=("_excel", "_final")
)

```

```

compare_lora["mismo_texto_excel_vs_final"] = (
    compare_lora["generated_text_norm_excel"]
    ==
    compare_lora["generated_text_norm_final"]
)

print("\nCoincidencia Excel LoRA vs FINAL_COMPARACION_36:")
display(
    compare_lora
    .groupby("system_name", as_index=False)
    .agg(
        textos=("sample36_id", "count"),
        coinciden=("mismo_texto_excel_vs_final", "sum"),
    )
    .assign(
        porcentaje=lambda d: (d["coinciden"] / d["textos"] * 100).round(2)
    )
)

print("\nEjemplos donde NO coincide Excel vs FINAL:")
display(
    compare_lora[
        ~compare_lora["mismo_texto_excel_vs_final"]
    ][
        [
            "sample36_id",
            "system_name",
            "texto_eval_id",
            "row_id",
            "generated_text_excel",
            "generated_text_final",
        ]
    ].head(10)
)

# =====
# 4) Comparación contra prompting para detectar copias
# =====
pivot_excel = qual_detail.pivot_table(
    index="sample36_id",
    columns="system_name",
    values="generated_text",
    aggfunc="first"
)

comparisons = [
    ("few-shot_hariel_llama3_llama3_cfg_3_R1", "lora_llama3"),

```

```

    ("few-shot_nancy_llama3_llama3_cfg_2_R2", "lora_mistral"),
]

print("\nComparación dentro del Excel interno / qual_detail:")
for a, b in comparisons:
    if a in pivot_excel.columns and b in pivot_excel.columns:
        same = (
            pivot_excel[a].fillna("").apply(norm_text)
            ==
            pivot_excel[b].fillna("").apply(norm_text)
        )
        print(f"{a} vs {b}")
        print("Textos idénticos:", same.sum(), "de", len(same))
        print("Porcentaje:", round(same.mean() * 100, 2), "%")
        print("-" * 80)
    else:
        print(f"No encontré columnas para comparar: {a} vs {b}")

```

ALL_SYSTEMS_FINAL: /home/harielpadillasanchez/Documentos/TT/TT2/FINAL_COMPARACION_36/04_todos_los_sistemas_sample36.csv | existe: True

LoRA desde Excel interno / qual_detail:

	sample36_id	texto_eval_id	system_name \
144	1	1	lora_mistral
145	2	2	lora_mistral
146	3	3	lora_mistral
147	4	4	lora_mistral
148	5	5	lora_mistral
149	6	6	lora_mistral
150	7	7	lora_mistral
151	8	8	lora_mistral
152	9	9	lora_mistral
153	10	10	lora_mistral

↳source_text \

144 No

↳tiene incentivos ni motivación, dos elementos esenciales en ambientes de

↳competencia.

145 En los procesos de importaciones y exportaciones intervienen, además de

↳clientes y proveedores, instituciones del Estado y los bancos, tal como se

↳indica en...

146 El robo de identidad ocurre cuando su información personal, tal como su

↳nombre, número de cuenta, o número de cédula de identidad se usan sin su

↳conocimiento...

147 Los sueños de los niños □
↳ tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por □
↳ Superman.

148 Expresiones como soborno y cohecho se refieren a □
↳ ilícitos vinculados a la compra de la voluntad de un individuo para provecho □
↳ personal.

149 □
↳ DIRECCIÓN DE PRESUPUESTO (DIPRES): "formula y lleva el control presupuestario □
↳ de la nación."

150 Interés compuesto: Es la suma del capital y el interés acumulado, que se va □
↳ multiplicando según los plazos convenidos. La tasa de interés es el porcentaje □
↳ q...

151 La producción en un país se realiza mediante lo que se conoce □
↳ como factores de producción y de los cuales nos ocuparemos en detalle más □
↳ adelante.

152 A pesar de □
↳ que algunos critican al intermediario, se necesita a este individuo en la □
↳ economía.

153 El impuesto a los réditos es □
↳ también un buen instrumento para conocer el monto de las rentas y de la □
↳ riqueza nacional.

↳ □ □
↳ □ □
↳ reference_text \ □

144 □
↳ No tiene sentido ni motivación. Estos elementos son esenciales para la □
↳ competencia.

145 Clientes y proveedores intervienen en las importancias y exportaciones. □
↳ También lo hacen las instituciones estatales y los banco como se indica a □
↳ continuación:

146 El robo de identidad ocurre cuando su información personal como su nombre, □
↳ número de cuenta, o número de cédula de identidad se usan sin su conocimiento □
↳ par...

147 Los □
↳ sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y □
↳ Superman.

148 Expresiones como soborno y cohecho se □
↳ refieren a delitos vinculados a comprar la voluntad de alguien para provecho □
↳ personal.

149 □
↳ DIRECCIÓN DE PRESUPUESTO: formula y lleva el control presupuestario de la □
↳ nación.

150 El interés compuesto es la suma del capital y el interés □
↳ acumulado. La tasa de interés es el porcentaje aplicado a un préstamo o □
↳ inversión realizada.

151 A través de los factores de producción se realiza
↳ la producción en un país. Más adelante nos ocuparemos en detalle de estos
↳ factores.

152 Aunque
↳ algunas personas critican al intermediario, este individuo es necesario en la
↳ economía.

153 El impuesto a las utilidades
↳ también es un buen método para conocer el monto de las rentas y de la riqueza
↳ nacional.

↳
↳ generated_text

144 No
↳ tiene incentivos ni motivación, dos elementos esenciales en ambientes de
↳ competencia.

145 En los procesos de importaciones y
↳ exportaciones intervienen clientes y proveedores, instituciones del Estado y
↳ los bancos.

146 El robo de identidad ocurre
↳ cuando su información personal se usa sin su conocimiento para cometer un
↳ fraude o robo.

147 Los sueños
↳ de los niños tienen una gran variedad. Algunos son Tarzán, el Agente 007 o
↳ Superman.

148 Expresiones como soborno y cohecho son
↳ ilícitos vinculados a la compra de la voluntad de un individuo para provecho
↳ personal.

149 La Dirección de Presupuesto formula y lleva el control presupuestario de la
↳ nación.

150 El interés compuesto es la suma del capital y el interés acumulado. Se
↳ multiplica según los plazos convenidos. La tasa de interés es el porcentaje
↳ que se ap...

151 La producción en un país se realiza mediante los factores de
↳ producción.

152 A pesar de
↳ que algunos critican al intermediario, se necesita a este individuo en la
↳ economía.

153 El impuesto a los réditos
↳ es un buen instrumento para conocer el monto de las rentas y de la riqueza
↳ nacional.

LoRA real desde FINAL_COMPARACION_36:

	sample36_id	row_id	system_name	\
0		1	550	lora_llama3
1		2	571	lora_llama3
2		3	885	lora_llama3
3		4	1193	lora_llama3
4		5	1391	lora_llama3
5		6	1399	lora_llama3
6		7	1636	lora_llama3
7		8	1740	lora_llama3
8		9	1742	lora_llama3
9		10	1790	lora_llama3

↪

↪source_text \

0 No

↪tiene incentivos ni motivación, dos elementos esenciales en ambientes de

↪competencia.

1 En los procesos de importaciones y exportaciones intervienen, además de

↪clientes y proveedores, instituciones del Estado y los bancos, tal como se

↪indica en...

2 El robo de identidad ocurre cuando su información personal, tal como su

↪nombre, número de cuenta, o número de cédula de identidad se usan sin su

↪conocimient...

3 Los sueños de los niños

↪tienen una gran variedad que va desde Tarzán hasta el Agente 007, pasando por

↪Superman.

4 Expresiones como soborno y cohecho se refieren a

↪ilícitos vinculados a la compra de la voluntad de un individuo para provecho

↪personal.

5 DIRECCIÓN

↪DE PRESUPUESTO (DIPRES): "formula y lleva el control presupuestario de la

↪nación."

6 Interés compuesto: Es la suma del capital y el interés acumulado, que se va

↪multiplicando según los plazos convenidos. La tasa de interés es el porcentaje

↪q...

7 La producción en un país se realiza mediante lo que se conoce

↪como factores de producción y de los cuales nos ocuparemos en detalle más

↪adelante.

8 A pesar de

↪que algunos critican al intermediario, se necesita a este individuo en la

↪economía.

9 El impuesto a los réditos es también

↪un buen instrumento para conocer el monto de las rentas y de la riqueza

↪nacional.

↪

↪reference_text \

0

↪No tiene sentido ni motivación. Estos elementos son esenciales para la

↪competencia.

1 Clientes y proveedores intervienen en las importancias y exportaciones.

↪También lo hacen las instituciones estatales y los banco como se indica a

↪continuación:

2 El robo de identidad ocurre cuando su información personal como su nombre,

↪número de cuenta, o número de cédula de identidad se usan sin su conocimiento

↪par...

3 Los

↪sueños de los niños son variados y van desde Tarzán hasta el Agente 007 y

↪Superman.

4 Expresiones como soborno y cohecho se

↪refieren a delitos vinculados a comprar la voluntad de alguien para provecho

↪personal.

5 DIRECCIÓN DE PRESUPUESTO: formula y lleva el control presupuestario de la

↪nación.

6 El interés compuesto es la suma del capital y el interés acumulado.

↪La tasa de interés es el porcentaje aplicado a un préstamo o inversión

↪realizada.

7 A través de los factores de producción se realiza

↪la producción en un país. Más adelante nos ocuparemos en detalle de estos

↪factores.

8 Aunque

↪algunas personas critican al intermediario, este individuo es necesario en la

↪economía.

9 El impuesto a las utilidades

↪también es un buen método para conocer el monto de las rentas y de la riqueza

↪nacional.

↪

↪generated_text

0 No

↪tiene incentivos ni motivación, dos elementos esenciales en ambientes de

↪competencia.

1 En los procesos de importaciones y exportaciones intervienen, además de

↪clientes y proveedores, instituciones del Estado y los bancos, como se indica

↪en el ...

2 El robo de identidad ocurre cuando

↪su información personal se usa sin su conocimiento para cometer un fraude o

↪robo.

- 3 Los sueños de los niños tienen una gran variedad.
- 4 Expresiones como soborno y cohecho se refieren a ilícitos vinculados a la compra de la voluntad de un individuo para provecho personal.
- 5 La Dirección de Presupuesto formula y lleva el control presupuestario de la nación.
- 6 El interés compuesto es la suma del capital y el interés acumulado. La tasa de interés es el porcentaje que se aplica a un préstamo o inversión realizada.
- 7 La producción en un país se realiza mediante los factores de producción. Estos se ocuparán en detalle más adelante.
- 8 Algunos critican al intermediario, pero se necesita a este individuo en la economía.
- 9 El impuesto a los réditos es un buen instrumento para conocer el monto de las rentas y de la riqueza nacional.

Coincidencia Excel LoRA vs FINAL_COMPARACION_36:

	system_name	textos	coinciden	porcentaje
0	lora_llama3	36	36	100.0
1	lora_mistral	36	36	100.0

Ejemplos donde NO coincide Excel vs FINAL:

Empty DataFrame

Columns: [sample36_id, system_name, texto_eval_id, row_id, generated_text_excel, generated_text_final]

Index: []

Comparación dentro del Excel interno / qual_detail:

few-shot_hariel_llama3_llama3_cfg_3_R1 vs lora_llama3

Textos idénticos: 0 de 36

Porcentaje: 0.0 %

few-shot_nancy_llama3_llama3_cfg_2_R2 vs lora_mistral

Textos idénticos: 0 de 36

Porcentaje: 0.0 %